Data Science

데이터 분석 과정 3-2

2021년 5월 15일 (2일간)

참고자료: DSAC Module3 교재

내용

분류 성능

분류의 손실 함수

- 분류에서는 손실함수로 MSE를 사용할 수 없다
- 대신, 분류에서 정확도(accuracy)를 손실함수로 사용할 수 있다
  - 예) 100명에 대해 남녀 분류 문제
    - 96명을 맞추고 4명을 오 분류 : 정확도 0.96
  - 그러나 정확도를 손실함수로 사용하는 데에는 다음과 같은 문제가 있다
- Category 분포 불균형시 문제
  - 예)
    - Group : 남자 95명, 여자 5명
    - 오 분류 케이스 – 남자 1명, 여자 3명
    - 정확도는 여전히 0.96 :
    - 문제 : 여자의 경우, 5명 중 3명을 오 분류 ➔ 결과 심각
  - 데이터 분포가 비대칭인 상황 : 질병 진단의 경우 자주 발생
  - 손실을 제대로 측정하지 못함
  - 이를 보완하기 위해서 크로스 엔트로피(cross entropy)를 사용
    - Category가 둘 이상인 경우에도 동일한 개념으로 적용 가능

크로스 엔트로피(Cross Entropy)

$$CE = \sum_i p_i \log\left(\frac{1}{p_i'}\right)$$

- p_i : 어떤 사건이 일어날 실제 확률, p_i' : 예측한 확률
- 남녀가 50명씩 같은 경우

$$CE = -0.5 \times \log\left(\frac{49}{50}\right) - 0.5 \times \log\left(\frac{47}{50}\right) = 0.02687$$

- 남자가 95명 여자가 5명인 경우

$$CE = -0.95 \times \log\left(\frac{94}{95}\right) - 0.05 \times \log\left(\frac{2}{5}\right) = 0.17609$$

- **크로스 엔트로피 값이 작을수록 분류가 잘 수행된 것**

대표적인 손실함수와 성능지표

	손실함수	성능 지표
정 의	손실함수를 줄이는 방향으로 **학습**	성능을 높이는 것이 머신러닝을 사용하는 **최종 목적**
회귀 모델	MSE (오차 자승의 평균)	R^2
분류 모델	크로스 엔트로피	정확도, 정밀도, 재현률, F1점수

분류 모델 성능

- 분석 모델이 얼마나 잘 동작하는지의 성능 평가 기준 필요
  - 예측의 정확도
  - 동작 속도
- 데이터 분석 프로젝트의 종료 기준으로 사전 정의

혼돈 매트릭스 – 다중 분류

y_pred

y_true	예측 클래스 0	예측 클래스 1	예측 클래스 2
정답 클래스 0	정답 클래스가 0, 예측 클래스가 0인 표본의 수	정답 클래스가 0, 예측 클래스가 1인 표본의 수	정답 클래스가 0, 예측 클래스가 2인 표본의 수
정답 클래스 1	정답 클래스가 1, 예측 클래스가 0인 표본의 수	정답 클래스가 1, 예측 클래스가 1인 표본의 수	정답 클래스가 1, 예측 클래스가 2인 표본의 수
정답 클래스 2	정답 클래스가 2, 예측 클래스가 0인 표본의 수	정답 클래스가 2, 예측 클래스가 1인 표본의 수	정답 클래스가 2, 예측 클래스가 2인 표본의 수

혼돈 매트릭스 – 이진 분류

- 혼돈 매트릭스(Confusion Matrix)
  - 분류의 결과가 잘 맞았는지를 평가하는 **채점표**와 유사
  - 오차 행렬로 번역하는 것이 더 타당함

- 결과 값이 P(Positive)또는 N(Negative) 둘 중 하나만 가질 수 있는 **binary 예측**의 경우를 설명하는 일반적인 용어

- Positive는 **찾고자 하는 현상**(ex. 암에 걸린 사실, 결함 등)이 나타난 것인지를 구분하는 것일 뿐, 긍정적인 결과를 찾았다는 뜻은 아님

실제 \ 예측	P로 예측	N로 예측
실제로 P	True positive (TP)	False negative (FN)
실제로 N	False positive (FP)	True negative (TN)

혼돈 매트릭스(Confusion Matrix)

- 용어의 의미 예시
  - True positive (TP)
    - 암/결함이라고 예측했는데 실제로 암에 걸린 경우
  - False positive (FP)
    - 암/결함이라고 예측했는데 실제는 암에 걸리지 않은 경우
  - False negative (FN)
    - 암/결함이 아니라고 예측했는데 실제는 암인 경우
  - True negative (TN)
    - 암/결함이 아니라고 예측했는데 실제로도 암이 아닌 경우

True: **예측이 맞음**	Positive: positive**로 예측**
False: **예측이 틀림**	Negative: negative**로 예측**

모델의 성능 지표 – 혼돈 매트릭스

- **정확도(accuracy): 정확하게 예측한 비율을 의미**
  - **accuracy = (TP+TN) / 전체 경우의 수(N)**

실제 / 예측	암(예측)	정상(예측)	합계
암환자(실제)	6 (TP)	4 (FN)	10
정상(실제)	2 (FP)	188 (TN)	190
합계	8	192	200

  - **암진단 정확도 = (6 + 188)/200 = 194/200 = 0.97 => 97%**
  - **오류율 = 1-accuracy = 0.03 => 오진율은 3%**
- **리콜/재현율(recall): 관심 대상을 얼마나 잘 찾아내는가**
  - **recall = TP / (TP+FN)**
  - **실제 암 환자 발견률 = 6 / (6+4) = 0.6 => 60%**
- **정밀도(precision): 예측의 정확도**
  - **precision = TP / (TP+FP) = 6 / (6+2) = 0.75 => 75%**

모델의 성능 지표

- recall과 precision의 두 가지 지표를 동시에 높이는 것은 어려움,
- F1은 이러한 두 요소를 동시에 반영한 새로운 지표임
- F1은 recall과 precision의 조화 평균을 구한 것

$$F1 = \frac{2 \times precision \times recall}{precision + recall}$$

- 두 지표의 값이 각각 0.5와 0.7일 때
  - 산술 평균 c=(a+b)/2=(0.5)+(0.7)/2=0.6
  - 조화 평균 c=2ab/(a+b)=0.7/1.2=0.58

- 두 지표의 값이 각각 0.9와 0.3일 때
  - 산술 평균 c=(a+b)/2=(0.9)+(0.3)/2=0.6
  - 조화 평균 c=2ab/(a+b)=0.54/1.2=0.45

조화 평균

조화 평균: $\frac{1}{c} = \frac{(\frac{1}{a} + \frac{1}{b})}{2}$

$$c = \frac{2ab}{a+b}$$

비용 최소화 – 병원 사례

- 1)의 경우 수익이 발생하며 이를 편의상 200만원 (E1)
- 2)의 경우 병원은 약간의 손실이 생기며 이를 -3만원 (E2)
- 3)의 경우는 병원에 큰 손실이 생기며 이를 -500만원 (E3)
- 4)의 경우 환자를 더 유치하므로 평균 이득이 2만원 (E4)
- 각 경우의 발생 확률과 각 이득 또는 비용을 곱하여 더하면 총 기대치를 구할 수 있다

비용 최소화 – 병원 사례

- **확률**

	암이라고 예측	암이 아니라고 예측
실제 암환자	p1 = 6/200=0.03	p3 = 4/200=0.02
실제로는 암 없음	p2 = 2/200=0.01	p4 = 188/200=0.94

- **기대치**

	암이라고 예측	암이 아니라고 예측
실제 암환자	E1 = 200만원	E3 = -500만원
실제로는 암 없음	E2 = -3만원	E4 = 2만원

비용 최소화 – 병원 사례

- **전체 기대치 : 위 두 테이블을 항목별로 곱한 후 더한다**

$$\begin{aligned}\text{전체 기대치} &= p1E1 + p2E2 + p3E3 + p4E4 \\ &= (0.03*200) + (0.01*(-3)) + (0.02*(-500)) + (0.94*2) = -7.55\text{만원}\end{aligned}$$

- **위의 의사는 암환자 진단 결과로 오히려 병원에 손실을 발생**
- **이렇게 손실이 발생한 원인은 무엇일까?**
  - **실제는 암인데 암이 아니라고 잘못 판정한 경우**

    (즉, FN의 댓가가 평균 -500만원으로 크기 때문)
  - **이 비용을 줄이려면 p3 확률을 줄이도록 노력해야 한다.**
  - **조금만 의심이 들어도 모두 "암 같은데요" 라고 판정해 주면 FN을 줄일 수 있다.**
  - **500만원 비용보다 -3만원 손실이 훨씬 적기 때문**

비용 최소화 – 병원 사례

- **보수적인 의사**

	암이라고 예측	암이 아니라고 예측
실제 암환자	10	0
실제로는 암 없음	90	100

실제 / 예측	암이라고 예측	암이 아니라고 예측
실제 암환자	p1 = 10/200=0.05	p3 = 0/200=0
실제로는 암 없음	p2 = 90/200=0.45	p4 = 100/200=0.5

$$\text{전체 기대치} = p1E1 + p2E2 + p3E3 + p4E4$$
$$= (0.05*200) + (0.45*(-3)) + 0 + (0.5*2) = 9.65\text{만원}$$

비용 최소화 – 병원 사례

- 이 의사의 진단 능력을 종합해 보면
  - 정확도(accuracy) : 55%로 나쁜 편 (110/200)
  - 재현률 : 10/10 = 100% (10명의 암환자를 모두 찾음)
- 앞의 의사의 경우
  - 정확도(accuracy) : 97%
  - 재현률(recall)이 60%
- 평가
  - 암 환자를 찾아내는 비율(재현률)이 높아졌다
    - 따라서 오진으로 인해 병원이 지출할 비용도 줄여주었다.
  - 그러나 정밀도(precesion)는 10 / (10+90) = 5%이며 이는 앞의 의사의 75%에서 크게 감소했다. 즉, 암이라고 진단해도 그 중에 5%만 암이고 나머지는 과잉 진단
  - 과잉 진단은 장기적으로 병원과 의사의 신뢰도를 떨어뜨릴 수 있다
- 판정 기준은 병원의 철학과 전체 비용에 따라 다르게 설정될 것이다.

동적 성능 평가

- 정적 성능 평가
  - 최종 분류의 결과만 본다

- 동적 성능 평가
  - 정적인 성능 평가 보다 알고리즘의 동작을 좀 더 세밀하게 평가
  - 최종 분류 결과만 보는 것이 아니라 분류한 순서를 평가하는 방법
  - ROC, AUC

분류 순서 평가

환자번호	성별	점수	순위	실제 값
7	F	0.98	1	N
125	M	0.96	2	C
4	F	0.95	3	N
199	M	0.86	4	C
2	F	0.84	5	N
200	M	0.82	6	C
176	M	0.81	7	C
73	M	0.80	8	N
82	M	0.79	9	C
3	F	0.77	10	N
123	F	0.76	11	N
		...		C
43	F	0.48	198	N
93	M	0.42	199	N
120	F	0.40	200	N

보수적

점수 : 예) 암일 확률

순서의 어디까지를 양성이라고 판정할지에 따라 혼돈 매트릭스가 달라진다

ROC (Receiver Operating Characteristic)

- 예측 결과를 순서대로 제시한 것이 실제 값과 얼마나 순서에 따라 잘 맞는지는 검증하는 2차원 그래프

- ROC 커브는 (0,0)점에서 시작하여 한 행씩 진행하면서 정답을 맞추었으면 y축 위로 한 칸 이동, 정답을 맞추지 못했으면 x축 방향으로 한 칸 이동. 종점은 (1, 1) 지점

- 그래프의 x 축으로는 예측 오류가 날 때마다 이동하고, y축으로는 정답을 맞출 때마다 이동

- x축은 예측이 틀린 것을 나타내므로 false positive rate, y축은 예측이 맞은 것을 나타내므로 true positive rate를 나타냄

분류 순서 평가

- 각 데이터 항목에 대해 계단형 그래프가 만들어짐
- 만일 의사의 예측 정확도가 높다면, 그래프가 초반에 위로 올라갈 것임

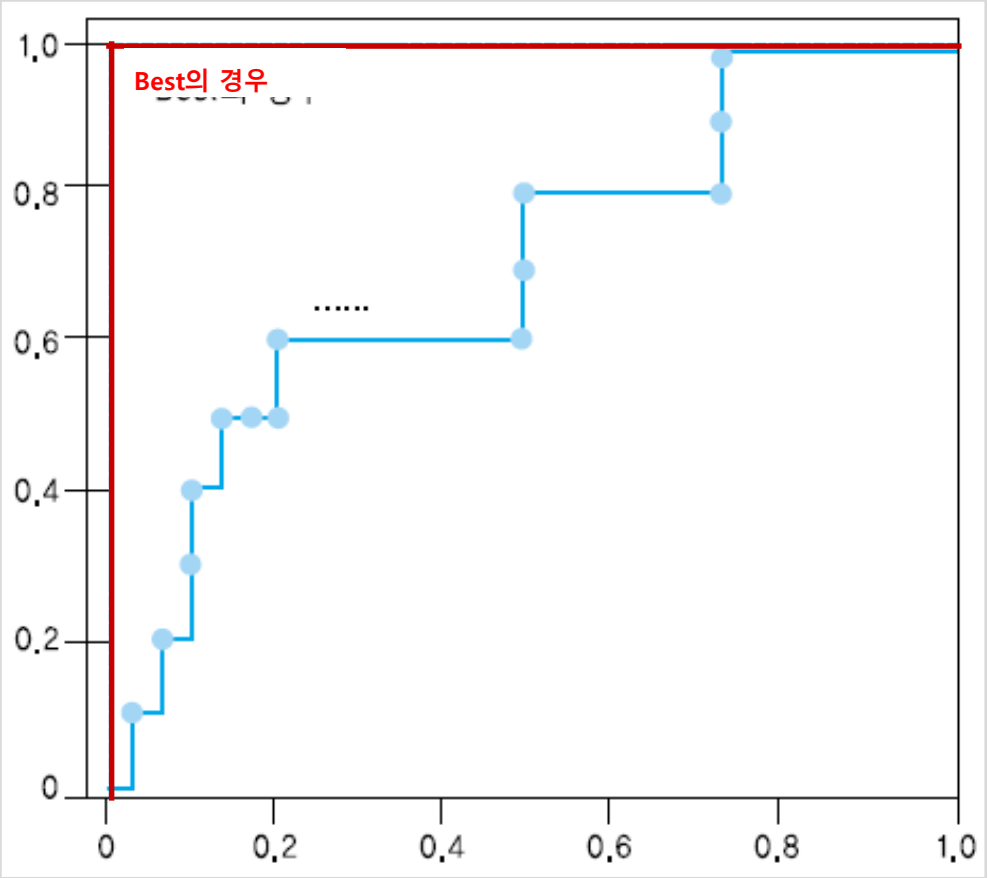

AUC (Area Under Curve)

- 예측 알고리즘의 성능을 간단히 수치로 나타내기 위해서 ROC 그래프의 면적을 계산하는 방법을 사용
- 우수한 알고리즘일수록 초반에 y축 상단 방향으로 이동하므로 ROC 커브의 면적이 넓어짐

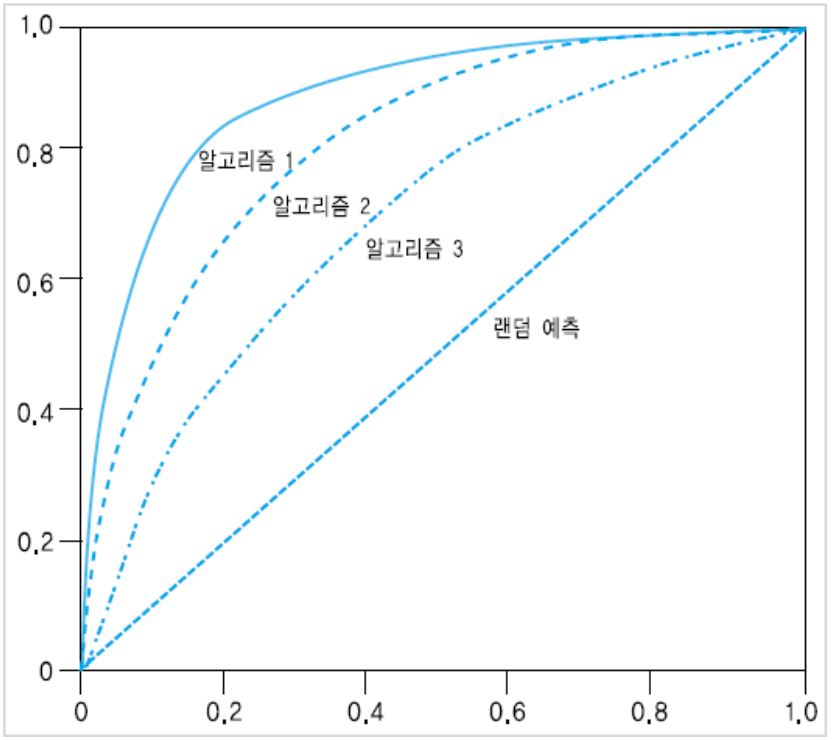

실습

- 분류성능 실습
  - <실습: gg-40-분류성능>
  - 오차 행렬(혼돈 매트릭스)를 통한 정적인 성능 평가
  - ROC 를 통한 동적인 성능 평가
  - <실습: gg-41-분류성능비교_포도주_ROC>
  - 포도주 품질 분류에 대해 성능 평가

다중 분류

- 다중 분류
  - 여러 개의 category를 가질 수 있는 입력 데이터를 분류
- sklearn의 이진분류 함수들은 다중 분류를 지원
  - 내부적으로 이진 분류를 확장해서 수행(해당 category인 것과 아닌 것)
  - 이러한 방식 : One-versus-Rest(OvR)방법
- 분류 결과만 알려면
  - predict()
- 다중 클래스 각각에 해당할 점수 또는 확률을 알려면
  - decision_function()
  - predict_proba()

다중 분류

- 3개 이상의 클래스 중에 하나를 예측해야 하는 경우
  - 로지스틱 회귀를 그대로 사용할 수 없다
  - 다항 로지스틱 회귀(multinomial logistic regression)를 이용
    - 다중 분류 (multiclass classification)
    - Softmax 함수 사용

- 이진 분류를 이용한 다중 분류 : OvR(One vs Rest) 방법
  - (예, A, B, C 분류)
    - A, {B, C}
    - B, {A, C}
    - C, {A, B}

- 한번에 다중 분류 가능 : 랜덤 포레스트, 나이브 베이즈 등
- 소프트맥스(softmax) 함수를 사용

$$\sigma(j) = \frac{\exp(\mathbf{w}_j^\top \mathbf{x})}{\sum_{k=1}^{K} \exp(\mathbf{w}_k^\top \mathbf{x})} = \frac{\exp(z_j)}{\sum_{k=1}^{K} \exp(z_k)}$$

소프트맥스 (Softmax)

- 소프트맥스(softmax) 함수를 사용

$$\hat{p}_k = \sigma(s(x))_k = \frac{\exp(s_k(x))}{\sum_{j=i}^{K} \exp(s_j(x))}$$

  - $\widehat{p_k}$: 클래스 k에 속할 확률
  - x : 주어진 샘플
  - $S_k(x)$: 소프트맥스 회귀 모델이 각 클래스k에 대한 점수

- 예) 얼굴을 보고 한국인, 중국인, 일본인 3 class로 구분
  - 어떤 샘플에 대해서 모델의 예측 값이 1.5, 2.0, 1.8 로 가정
  - 소프트맥스 적용 : 0.23, 0.43, 0.34 (합 = 1.0)
    - 각각의 점수를 확률처럼 사용 가능
    - 모델 예측 값이 음수(-)이어도, 소프트맥스 출력 값은 0~1 사이 값

소프트맥스

- 상대적인 점수 비교 : 확률처럼 0~1 사이 값으로 매핑

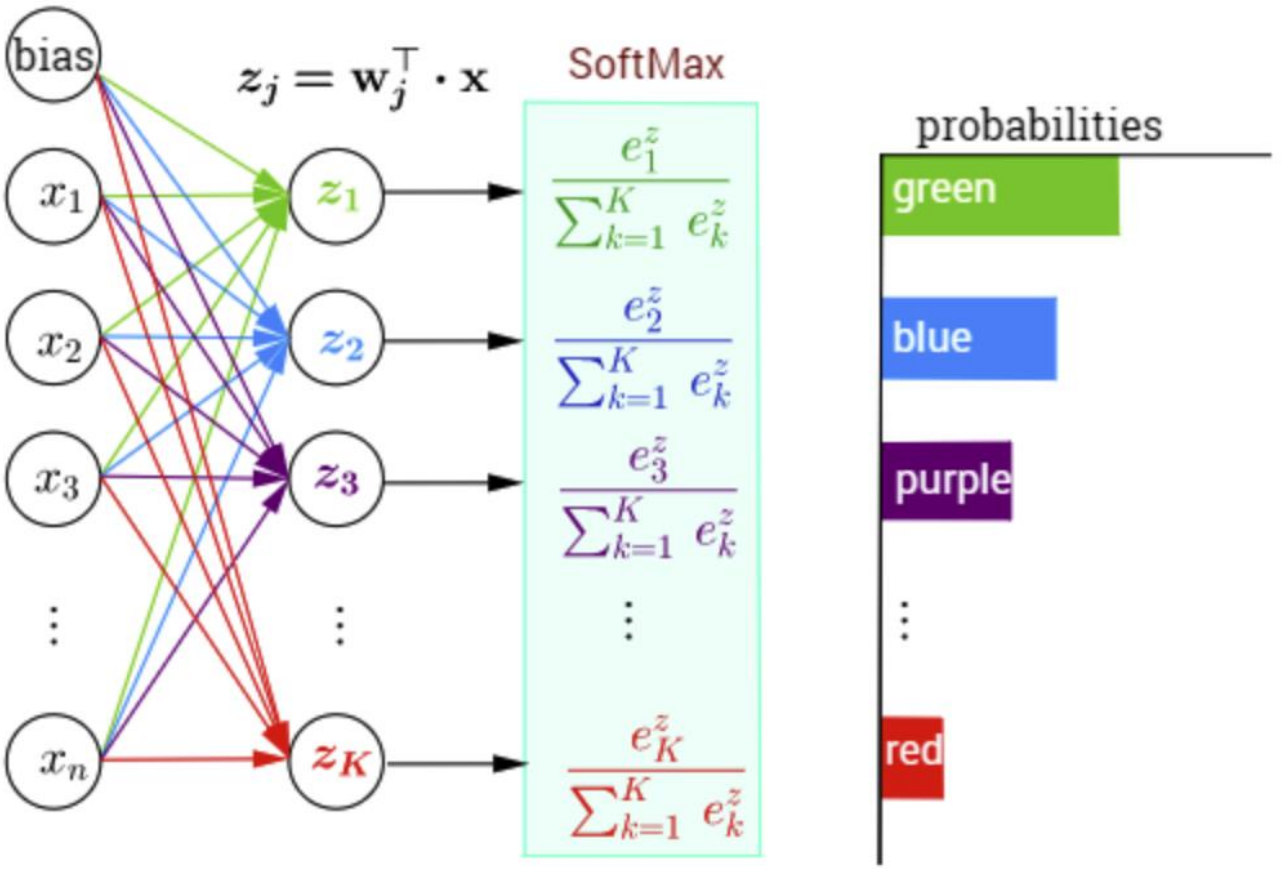

특성공학

차원 축소

- 기존 여러 특성 중 분석에 가장 영향력이 있는 특성을 선택하는 것이 필요한 때가 있다
  - 학생들의 학업 능력을 평가
    - 모든 과목의 성적을 다 사용하지 않고 국어, 수학 성적이 대표성이 있다면 이 두 과목의 성적만 평가 점수로 사용

- 특성 공학
  - 머신 러닝에서 사용할 특성을 잘 선택하는 것
  - 유효한 특성을 잘 선택하면 학습 속도가 빨라지고 성능도 좋아진다.

- 차원 축소
  - 머신 러닝의 성능을 떨어뜨리지 않으면서 특성의 수를 줄이는 기술

- 차원 축소가 필요한 이유
    - 계산량, 메모리 사용량을 줄이기 위해
    - 샘플의 특징을 보기 좋게 시각화하기 위해

차원의 저주

- 이론적으로 특성의 수가 증가할수록 더 좋은 성능을 가질 가능성이 큼
- 차원의 저주
  - 실제로는 특성의 수가 증가하면 더 나쁜 성능을 가짐
- 사례
  - 반지름이 1인 구/hypersphere 인 경우 차원이 커질수록 부피가 점점 작아짐
  - 즉, 구가 포함된 박스 안의 임의 지점을 샘플링하면 차원이 커질수록 대부분 지점이 구 바깥에 존재
  - 다르게 표현하면 차원이 커질수록 박스 안의 임의의 두 지점 간 평균거리가 점점 커짐
    - 1x1 4각형: 평균 거리 0.52m, 3차원큐브: 0.62m,
    - 1백만차원 하이퍼큐브: 408.25m
- 훈련 예제의 수는 차원에 따라 기하급수적으로 증가되어야 함

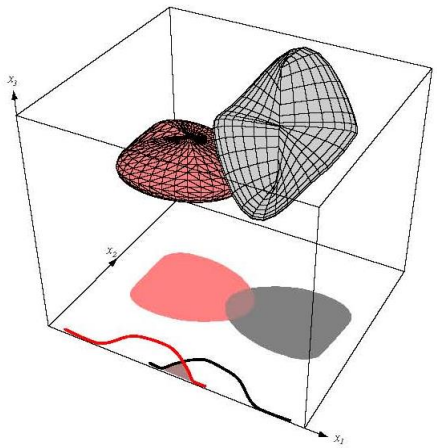

차원 축소

- 자동으로 영향력이 큰 특성 선택 방법
  - 목적 변수와 상관관계가 높은 변수를 선택
  - SelectPercentile()
    - 상관관계가 높은 순서대로 특성들을 나열하고
    - 상위 몇 %까지의 특성을 선택해 줌

- 머신 러닝에 별로 도움이 되지 않는 특성들을 제거함으로써 모델 개발 시간을 줄일 수 있다

차원 축소

- 차원 축소
  - 고차원 데이터 지점을 저차원 지점으로 단순화하는 방법
  - 차원의 저주를 극복하는 대표적인 방법
  - 투영(Projection)과 매니폴드 학습(manifold learning) 등의 방식

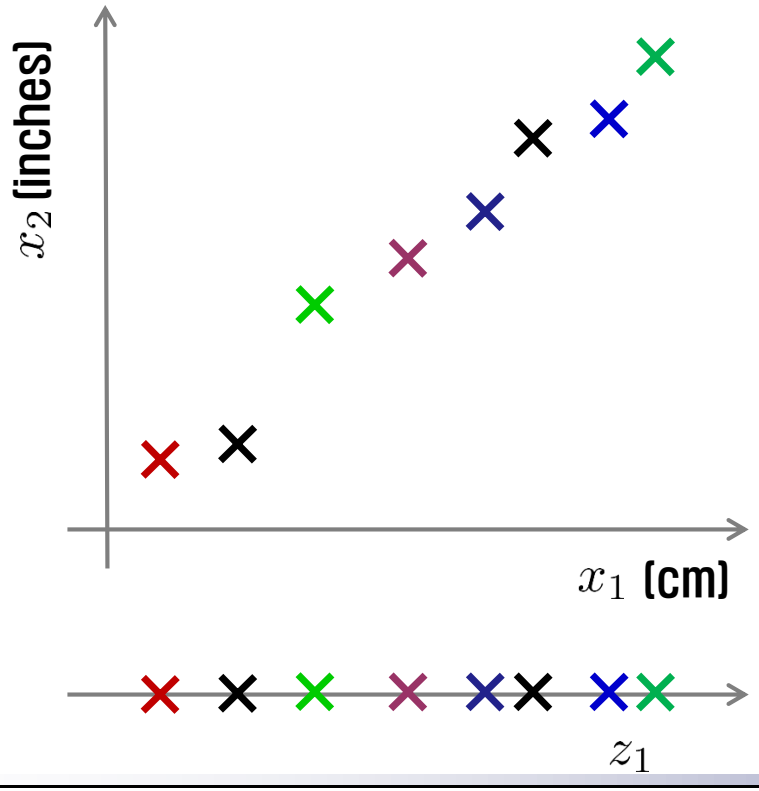

2D에서 1D로 데이터 축소

$$x^{(1)} \rightarrow z^{(1)}$$
$$x^{(2)} \rightarrow z^{(2)}$$
$$\vdots$$
$$x^{(m)} \rightarrow z^{(m)}$$

차원 축소

- 투영
  - 예) 3D에서 2D로 데이터 축소

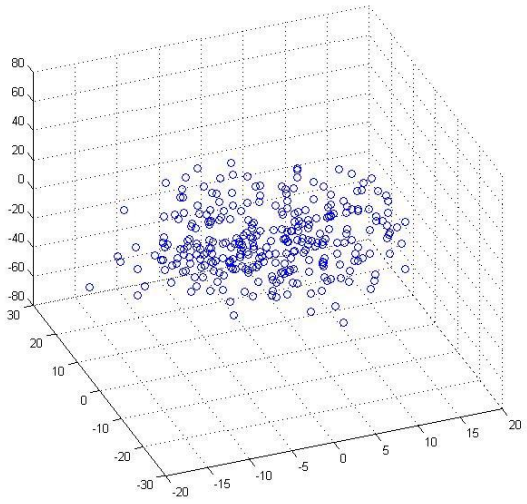

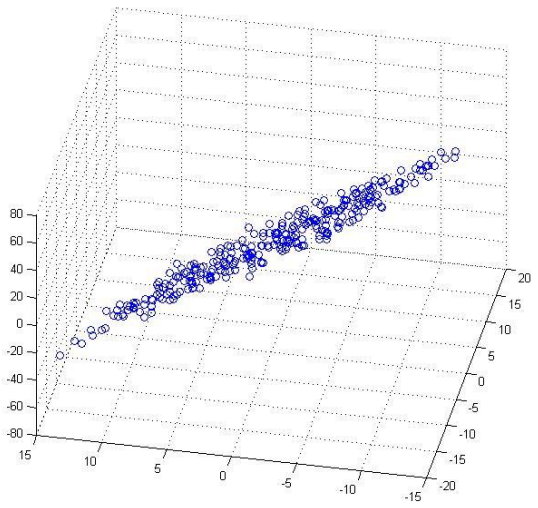

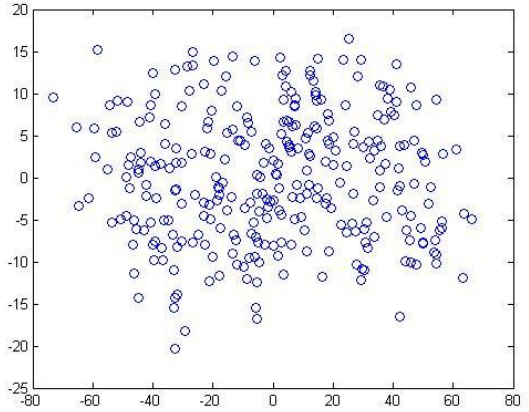

주성분 분석 (PCA)

- 주성분 분석 (Principal Component Analysis)
  - 여러 속성들을 조합하여 이들을 대표할 수 있는 적은 수의 특성을 찾아내는 작업
  - 기존 속성들의 선형 조합 : 가장 많이 사용
    - 예 : 학생의 능력 – 주성분 (수업 능력, 활동 지수)
    - 수업 능력 : 국어, 영어, 수학 성적(가중치 0.4, 0.3, 0.3)을 각각 곱해 더한다
    - 활동 지수 : 독서량, 운동량, 친구(가중치 0.4, 0.3, 0.3)을 각각 곱해 더한다
- 가장 적절한 주성분 찾기
  - 기존의 속성 값들을 어떤 비율로 가중 합산해야 할 지는 컴퓨터가 자동으로 여러 조합을 만들어 보고 최적의 조합을 찾아준다
- 최종적으로 필요한 주성분의 개수는 알려 주어야 한다.

주성분 분석 (PCA)

- 주성분 분석 (Principal Component Analysis)
  - 데이터 집합의 좌표 시스템을 새로운 좌표 시스템으로 변환
  - 가능한 한 많은 정보가 유지되도록 하는 투영 변환을 찾음
    - 공분산 행렬의 고유벡터 중 가장 큰 방향 벡터들이 주성분 임
  - 특성들이 통계적으로 상관관계가 없도록 데이터 집합을 회전

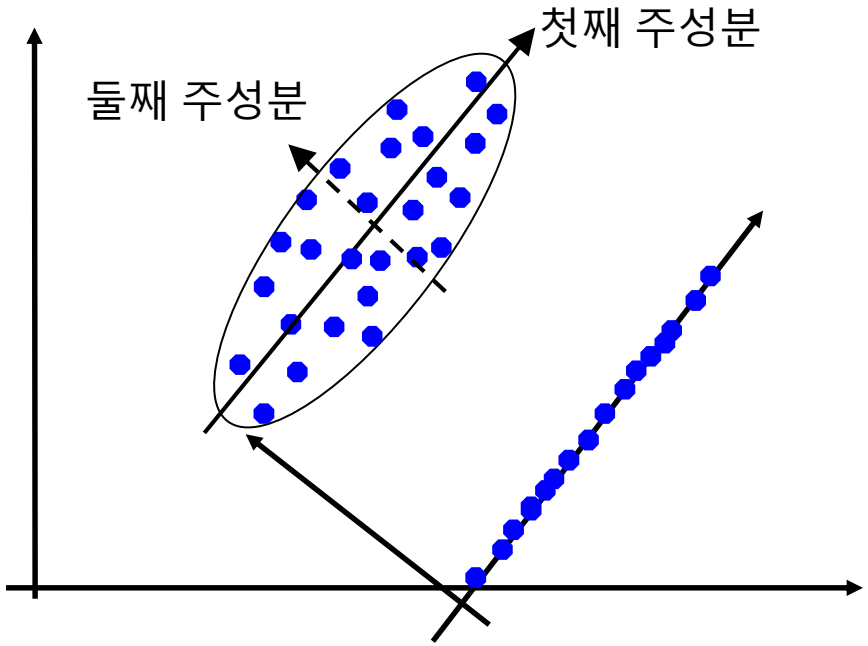

주성분 분석 (PCA)

- 주성분 분석 순서
  - 분산/정보를 가장 잘 유지하는 저차원 투영식을 구함
  - 데이터 셋에 대한 평균 벡터와 공분산 행렬을 계산
    - $\boldsymbol{\mu} = \frac{1}{N}\sum_{j=1}^{N} \boldsymbol{x_j}$
    - $\boldsymbol{\Phi_i} = \boldsymbol{x_i} - \boldsymbol{\mu},\ \boldsymbol{\Phi} = [\boldsymbol{\Phi_1}\boldsymbol{\Phi_2}\cdots\boldsymbol{\Phi_N}]$
    - $\mathbf{C} = \frac{1}{N}\sum_{j=1}^{N}(\boldsymbol{x_i} - \boldsymbol{\mu})(\boldsymbol{x_i} - \boldsymbol{\mu})^T = \frac{1}{N}\boldsymbol{\Phi}\boldsymbol{\Phi}^T$
  - 공분산 행렬에 대한 고유벡터와 고유값 계산
    - $\boldsymbol{eig}(\mathbf{C}) = \{\boldsymbol{\lambda_1} > \boldsymbol{\lambda_2} > \cdots > \boldsymbol{\lambda_N}\},\ \boldsymbol{eigvec}(\mathbf{C}) = \{\boldsymbol{c_1}, \boldsymbol{c_2}, \cdots, \boldsymbol{c_N}\}$
    - 고유벡터는 SVD 를 통해서도 구할 수 있음
      - $\mathbf{C} = \mathbf{U}\boldsymbol{\Sigma}\mathbf{V}^T,\ \mathbf{V}^T = (\boldsymbol{c_1} \quad \boldsymbol{c_2} \quad \cdots \quad \boldsymbol{c_n})$
  - 가장 큰 고유벡터들을 선택하고 이들로 구성된 부공간으로 투영
    - $\boldsymbol{y} = \boldsymbol{A}(\boldsymbol{x} - \boldsymbol{\mu})$

t-SNE (Stochastic Neighbor Embedding)

- 데이터의 특성을 한 눈에 파악하는데는 시각화가 매우 유용
  - 그러나 실제 세계의 데이터는 속성의 차원이 높으므로 이러한 다차원 공간에 속성들의 관계를 그리는 것은 불가능
  - 명확한 시각화를 위해서는 데이터를 2, 3차원 이하로 변환 필요
    - 비지도 학습
- t-SNE
  - 시각화를 위해 고차원의 특성을 가진 데이터를 저차원으로 축소하는 기술
  - 데이터 지점 사이의 거리를 가장 잘 보존하는 2차원 표현을 찾기 위해서 각 데이터 지점을 2차원에 무작위로 표현한 후 원본 특성 공간에서 가까운 지점은 가깝게, 먼 지점은 멀어지게 함. 데이터 지점 간의 거리를 확률로 변환
  - 보통 word2vec으로 임베딩한 단어벡터를 시각화하는 데 많이 사용
  - 단, 계산 시간이 많이 걸림

t-SNE

- MNIST 데이터 30개
  - 28x28의 차원(즉, 784 차원)의 데이터
  - 2차원으로 축소 : PCA, t-SNE

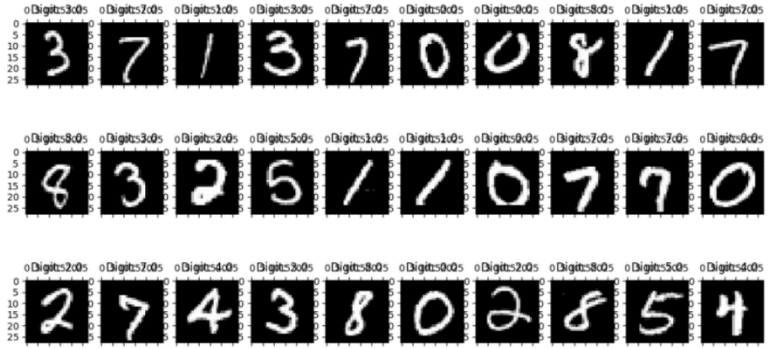

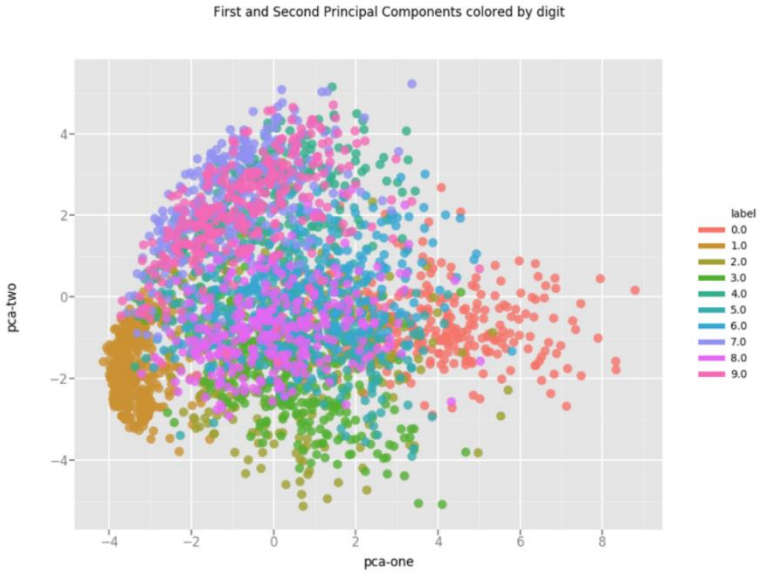

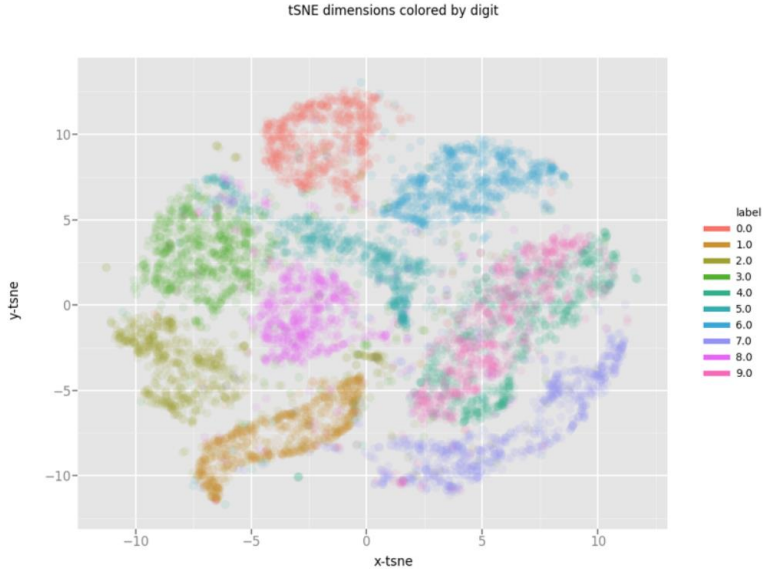

실습

- 분류성능 실습
  - <실습: gg-40-분류성능>
  - 오차 행렬(혼돈 매트릭스)를 통한 정적인 성능 평가
  - ROC 를 통한 동적인 성능 평가
  - <실습: gg-41-분류성능비교_포도주_ROC>
  - 포도주 품질 분류에 대해 성능 평가

모델 최적화

릿지 규제

- 모델을 일반화 하는 방법으로, 손실함수로 MSE 항목과 함께 계수의 크기 자체도 줄이도록 하는 방법을 도입한 것

$$J(W) = MSE(W) + \alpha \frac{1}{2} \sum_{i=1}^{n} W_i^2$$

- 계수의 자승의 합을 손실함수에 추가
  - 계수 자체가 가능하면 작은 값이 되기를 원한다
  - α : 이 축 항목의 비중을 얼마나 크게 할지를 정하는 하이퍼파라미터
- 이는 여러 계수들을 가능한 골고루 반영하라는 의미
  - 왜냐하면 계수의 자승의 합을 줄이려면 각 계수의 크기를 줄여야 전체 자승의 합이 최소화되기 때문

릿지 규제

- 그러나 릿지 규제를 너무 강하게 하면 MSE 항은 무시되고, 모든 계수의 값이 동일하게 된다.
- 릿지 규제는 선형회귀에서만 사용되는 것이 아니라 SVM, 신경망 등 다른 머신러닝 모델에서도 사용될 수 있다.
- 릿지 규제는 L2 규제라고도 부른다

라쏘 규제

- 라쏘 규제에서는 모든 계수의 절대치들의 합을 추가로 더하는 방법 (자승을 취하지 않음)

$$J(W) = MSE(W) + \alpha \sum_{i=1}^{n} |W_i|$$

- 릿지 규제와 유사한 것처럼 보이지만 사실은 반대의 효과
- 릿지 규제에서는 특별히 비중이 큰 계수를 지양하고, 가능한 여러 가중치를 골고루 반영하는 효과
- 라쏘 규제를 적용하면 절대값이 작은 계수가 먼저 사라지는 효과
  - 라쏘 규제는 L1 규제라고도 함

엘라스틱 넷

- 릿지 규제와 라쏘 규제가 동시에 필요한 경우가 있다.
  - 특정 계수가 크게 영향을 주는 것을 피하고 싶고(L2 규제)
  - 동시에 영향력이 적은 계수의 수를 줄일 필요가 있다(L1 규제)
- 아래에서
  - α : 일반화의 정도를 조정하는 하이퍼파라미터
  - λ : L2와 L1 규제의 반영 비중을 조절하는 하이퍼파라미터

$$J(\theta) = MSE(\theta) + \gamma\alpha\sum_{i=1}^{n}|\theta_i| + \frac{1-\gamma}{2}\alpha\sum_{i=1}^{n}\theta_i^2$$

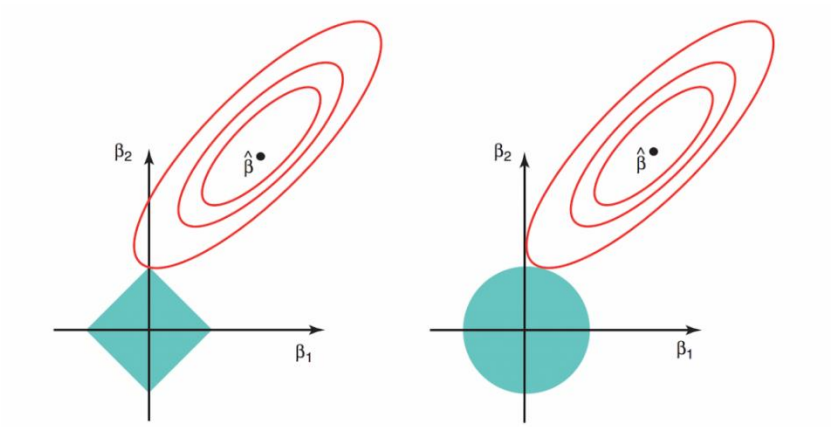

과소 적합과 과대적합 판단 – 손실함수

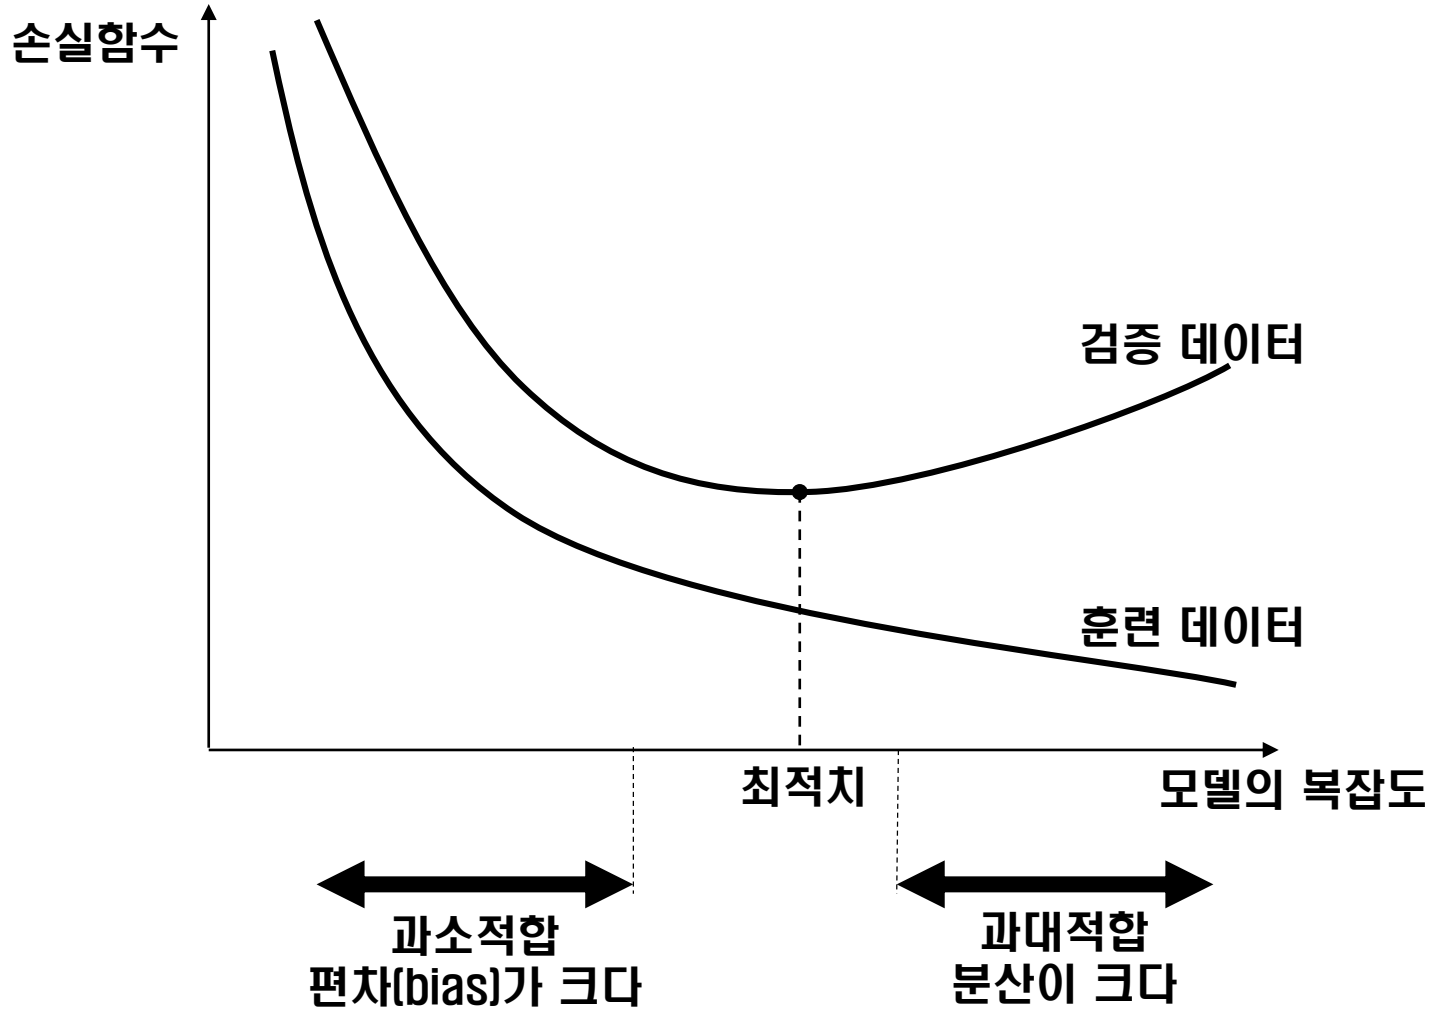

과소 적합과 과대 적합 판단 – 성능

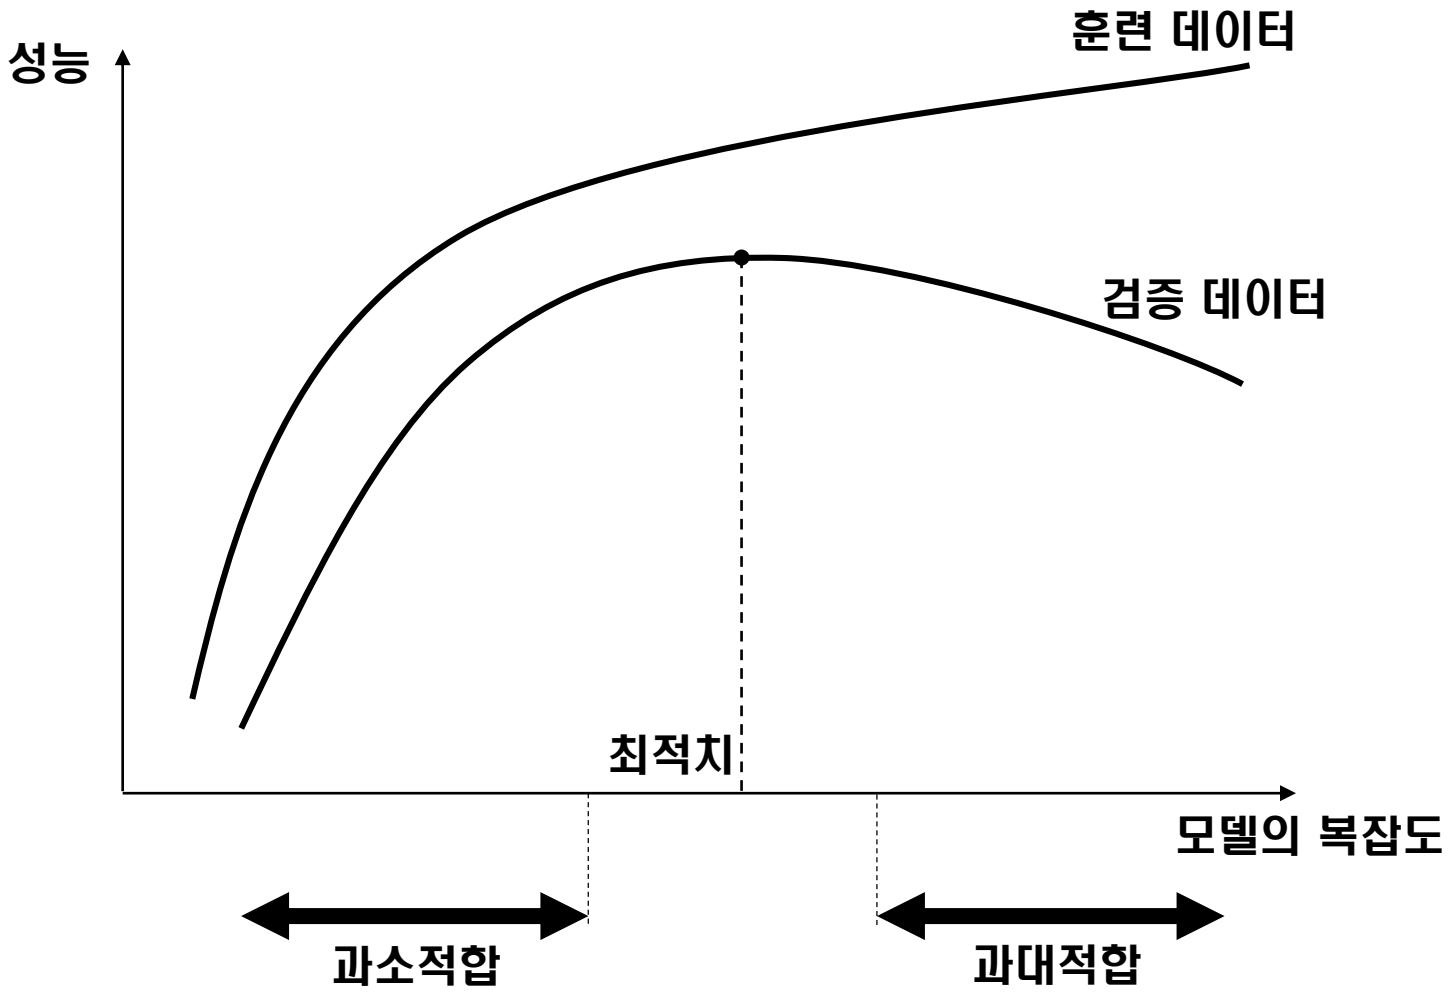

편향과 분산

- 예측 모델에서 발생하는 오차는 분산(variance)과 편향(bias) 두 가지 성분으로 설명할 수 있다.
- 분산이란 모델이 너무 복잡하거나 학습데이터 민감하게 반응하여 예측 값이 산발적으로 나타나는 것이다.
- 편향이란 모델 자체가 부정확하여 피할 수 없이 발생하는 오차를 말한다.

편향과 분산

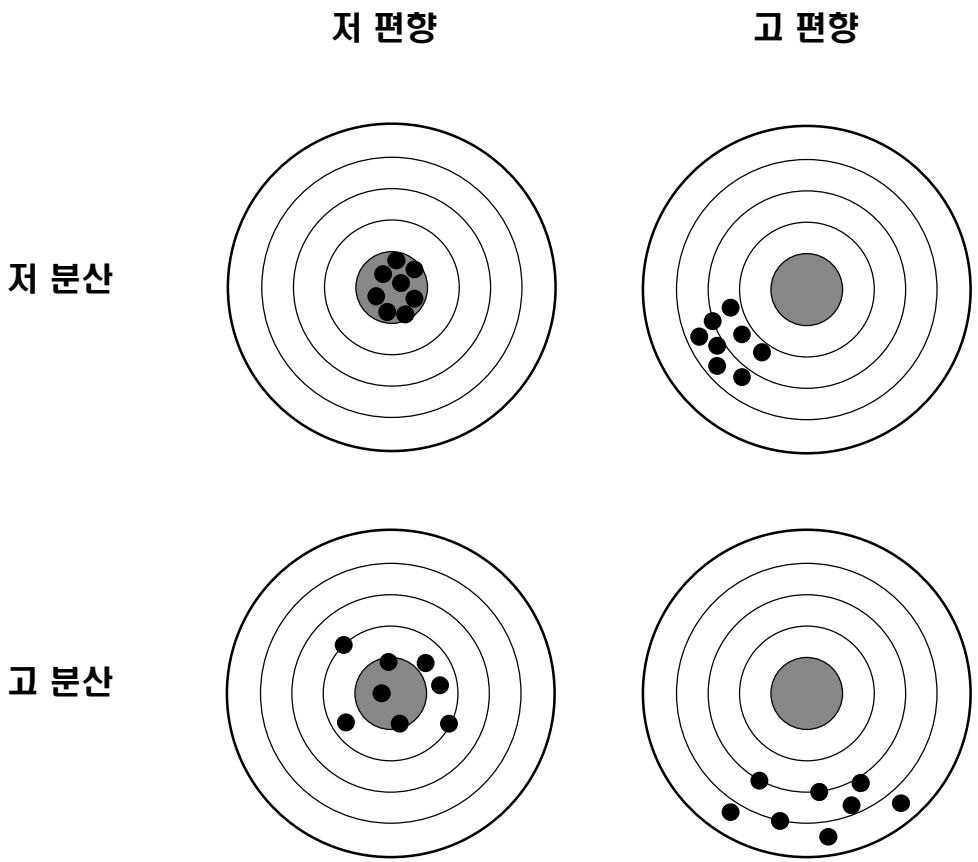

실습

- 선형모델규제 실습
  - <실습: gg-43-선형모델규제>
  - 슈퍼마켓 매출을 예측하는 선형모델 비교
  - 릿지 및 라쏘 규제 실습

이미지 분석

영상 분석 개요

- 영상 분석
  - 컴퓨터를 사용하여 영상 데이터를 분석하여 중요한 의미를 추출하거나 미시각 기능을 가진 장치을 만드는 기술

- 분야
  - 영상 처리 (Processing)
  - 검출 (Detection)
  - 분류 (Classification)
  - 인식 (Recognition)

영상 처리

- 영상을 입력으로 받아 처리하여 새로운 영상을 출력

- 필터링
- 이진화
- 모폴로지
- 기하학적 변환
- 영상 변환
- 영상 분할

컴퓨터 비전 처리 과정

- 전처리
  - 주로 영상 처리

- 특징 추출
  - 에지, 선분, 영역, 텍스처, 지역 특징 등을 검출하고 특징 벡터 추출

- 해석
  - 응용에 따라 다양한 형태

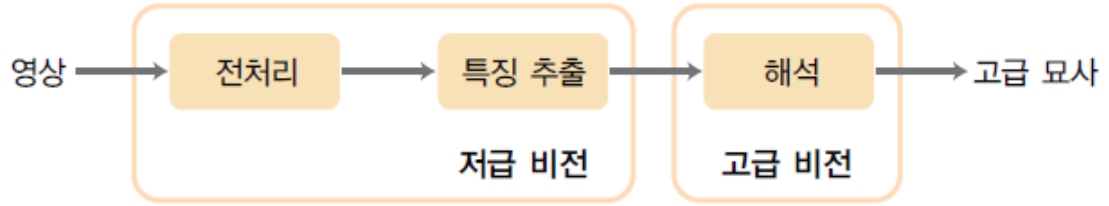

그림 1–6 컴퓨터 비전의 계층적 처리

검출

- 영상을 입력으로 받아 특징 또는 객체를 검출

- 특징 검출
  - 에지 검출
  - 지역 특징 옥타브 1 검출
- 특징 기술
  - 관심점 기술자 – SIFT, SURF
  - 영역 기술자 – 모멘트, 모양, 푸리에 기술자
  - 텍스쳐, 지역 관계 기술자 - LBP

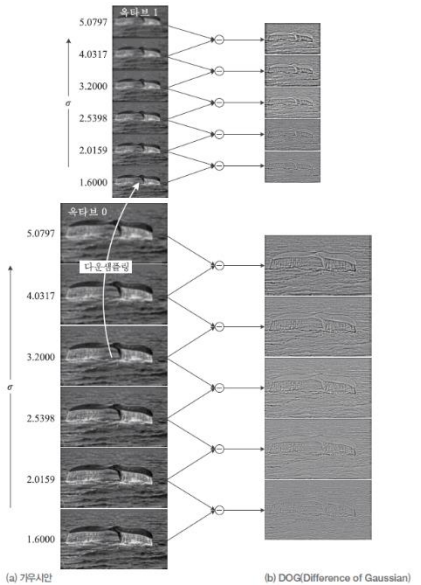

그림 4-16 SIFT가 사용하는 스케일 공간(DOG 피라미드 구조)

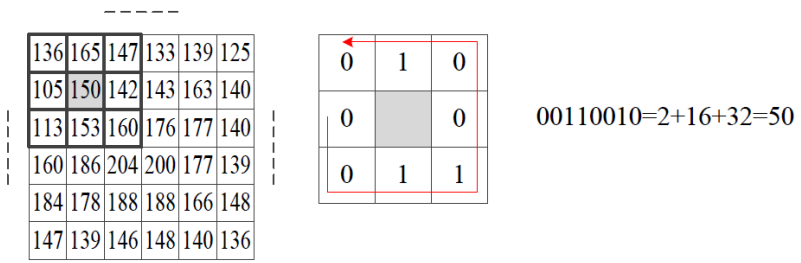

그림 6-17 LBP 계산

영상 분류

- 영상을 입력으로 받아 객체를 분류
- 유형별 분류
  - 문자인식
  - 딥러닝을 활용한 영상 객체 분류
- 범주 분류
- 대표적인 컴퓨터비전 대회
  - PASCAL VOC(http://host.robots.ox.ac.u
    - 분류(20),검출,분할에 대한 5가지 문제
    - 2012년 종료
  - ImageNet ILSVRC(http://www.image-ne
    - 1000종류 분류 문제
    - 2017년 인간의 성능을 능가하면서 종료
  - ICDAR RRC
    - 자연 영상에서 텍스쳐 검출

(a) 사례 인식

(b) 범주 인식

그림 9-2 사례 인식과 범주 인식

영상 인식

- 영상을 입력으로 받아 객체를 감지하고 분류하고 인식

- 객체 탐지
  - 사물 및 위치 인식
  - 얼굴인식
- 영상 분할
  - 의미론적 분할
  - 객체 분할
- 3D 객체 인식
  - Objectron

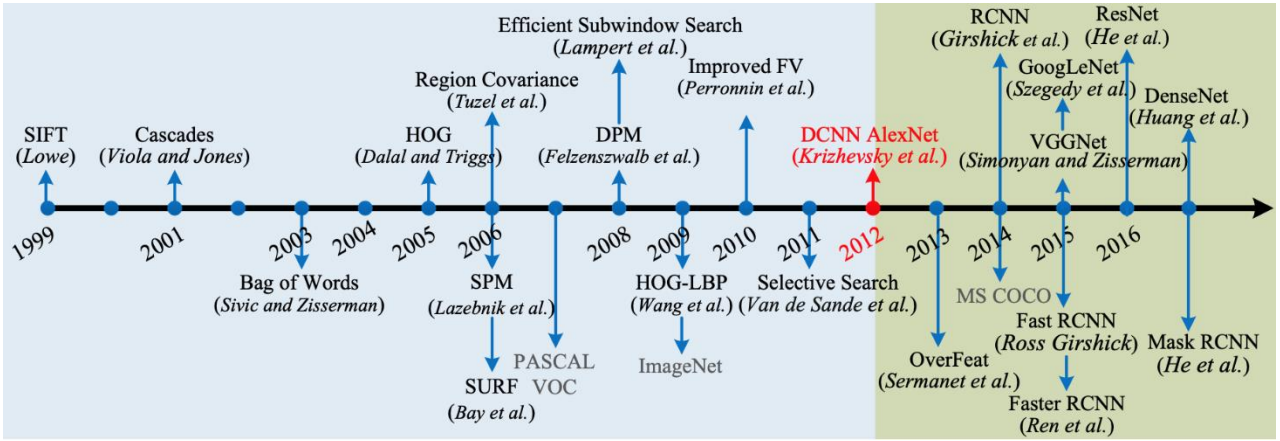

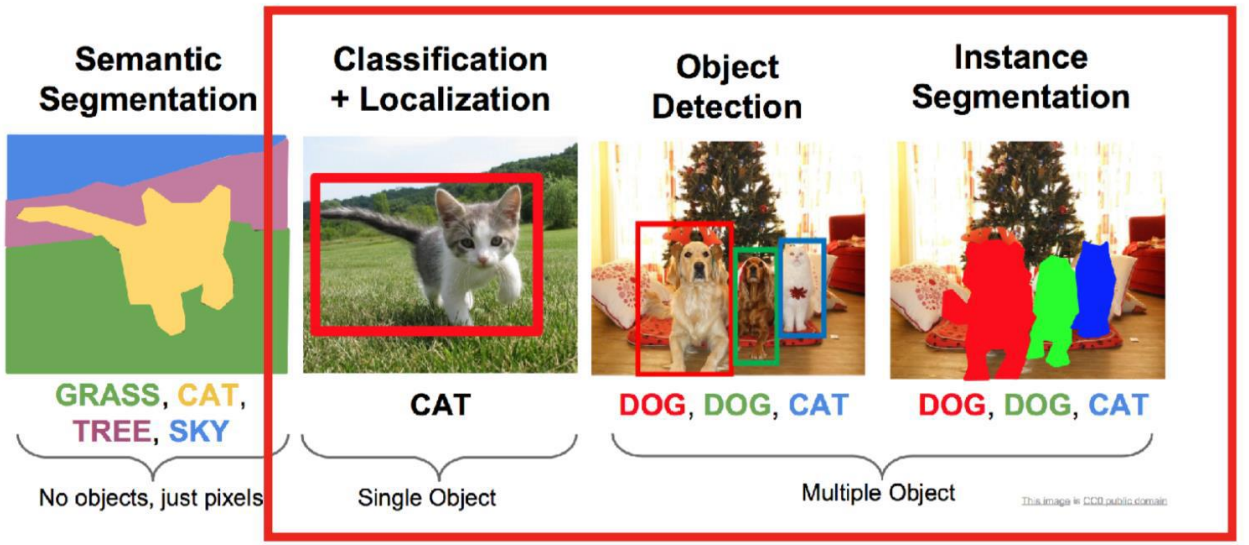

OpenCV 개요

- OpenCV
  - 인텔 주도로 개발된 컴퓨터 비전용 라이브러리
  - 픈 소스 소프트웨어 (BSD 라이선스)
  - 공식 웹 사이트는 http://opencv.org/이다.
- 지원 기능
  - OpenCV는 영상처리, 얼굴 인식, 물체 감지, 비디오 캡처 및 분석, 딥러닝 프레임워크인 TensorFlow, Torch/PyTorch, Caffe도 지원하고 있다.
  - 인텔의 데이터 중심 연산 최적화 라이브러리인 IPP(Integrated Performance Primitives)가 설치되어 있으면 활용
- 주요 기능
  - 영상 파일의 읽기 및 쓰기
  - 비디오 캡처 및 저장
  - 영상 처리(필터, 변환)
  - 영상이나 비디오에서 얼굴, 눈, 자동차와 같은 특정 물체를 감지
  - 비디오를 분석하여 움직임을 추정하고, 배경을 없애고, 특정 물체를 추적
  - 기계 학습 알고리즘을 사용하여 물체 인식 가능

OpenCV 개요

- **라이브러리 구성**
  - **현재 4.5 버전까지 개발**
  - **기본 기능**

패키지명	기능	패키지명	기능
core	핵심 기능	ml	기계 학습
imgproc	이미지 처리	flann	다차원 클러스터링 및 탐색
highgui	고급 GUI 및 미디어 I/O	gpu	GPU 가속
video	비디오 분석	photo	연산 사진술(photography)
calib3d	카메라 캘리브레이션 및 3D 재구성	stitching	이미지 스티칭(붙이기)
features2d	2D 특징 추출 프레임워크	gapi	그래프 API
objdetect	객체 탐지	nonfree	유료 기능
dnn	심층 신경망	contrib	기증된/실험적인 기능

  - **추가 기능 : aruco(마커 탐지), cnn_3dobj(3D 객체인식및자세추정),cudaxx(가속기능), rgbd(RGB-깊이처리), tracking(객체추적), viz(3D시각화) 등**

OpenCV 설치

- 아나콘다 환경에서 OpenCV 설치
  - conda install OpenCV 를 입력하여 설치
- 코랩 환경에서 OpenCV 설치
  - pip install opencv-pytyon 입력하여 설치
- 설치 확인
  - 파이썬 쉘(Python shell)에서 아래의 명령을 입력하여 OpenCV버전을 확인
  - >>> import cv2
  - >>> print(cv2.__version__)

```
(cm) C:₩Users₩cm>python
Python 3.6.10 |Anaconda, Inc.| (default, May  7 2020, 19:46:08) [MSC v.1916 64 bit (AMD64)] on win32
Type "help", "copyright", "credits" or "license" for more information.
>>> import cv2
>>> print(cv2.__version__)
3.4.4
>>>
```

- 파이썬 예제 참고자료
  - https://wjddyd66.github.io/categories/#opencv

주요 함수

- 이미지 읽기 : cv2.imread()
  - 컬러 이미지를 읽으려면 cv2.IMREAD_COLOR를, 그레이스케일 모드로 읽으려면 cv2.IMREAD_GRAYSCALE을 입력
- 이미지 컬러 공간 변환 : cv2.cvtColor()
  - BGR 색공간→gray-scale로 변환 : cv2.COLOR_BGR2GRAY,
  - BGR 색공간→HSV 색공간으로 변환 : cv2.COLOR_BGR2HSV를 선택
- 이미지 사이즈 변경 : cv2.resize()
  - 이미지를 축소시킬 때는 보간법(interpolation) 설정을 cv2.INTER_AREA로, 확대시킬 때는 cv2.INTER_CUBIC 또는 cv2.INTER_LINEAR를 사용
- 이미지 보여주기 : cv2.imshow()
  - 보통 cv2.waitKey(0), cv2.destroyAllWindows()와 함께 사용
- 이미지 저장 : cv2.imwrite()
- 선/사각형/원/타원 그리기 : cv2.line(), cv2.rectangle(), cv2.circle(), cv2.ellipse()
- 텍스트 넣기 : cv2.putText()
- 이미지 채널 분리 및 병합 : cv2.split(), cv2.merge()
- 값의 범위 바꿔주기 : cv2.normalize()

실습

- OpenCV 기본 동작 실습
  - <실습:gg-44-opencv_intro>
  - 얼굴인식
    - 최근 딥러닝 기술이 아니라 OpenCV가 제공하는 패턴 인식 기술 활용
    - 사람 얼굴에는 공통된 특징이 있어서 모든 사람의 눈,코,입 부분의 명암의 매우 유사한 패턴을 가지고 있다.
    - 이러한 얼굴 고유의 특징을 데이터베이스화하여 사람의 얼굴을 이미지에서 추출하는 방법으로 캐스케이드 파일을 이용할 수 있다.
    - haarcascade 검색하면 찾을 수 있으며 아래는 Haar-like 특징 학습기를 다운로드 받는 방법이다.

얼굴 인식 (openCV)

- **Haar-like 특징 학습을 이용한 얼굴 인식**
  - 사람 얼굴에는 공통된 특징이 있다
    - 예) 모든 사람의 눈, 코, 입 부분의 명암이 매우 유사한 패턴
  - 3종류의 특징 사용
    - A, B(Two-rectangle feature)
    - C(Three-rectangle feature)
    - D(four-rectangle feature)
  - 입력영상에서 A,B,C,D와 같은 Sub-Window를 Sliding시켜 탐색
  - 영상에서 검정 부분과 흰색 부분의 밝기 값을 빼서 임계값 이상인 것을 찾는다.
  - 이때 Sub-Window내의 feature의 크기와 모양은 다양할 수 있다.
    - 단, sliding window(검정부분과 흰색부분의 크기와 모양)은 동일

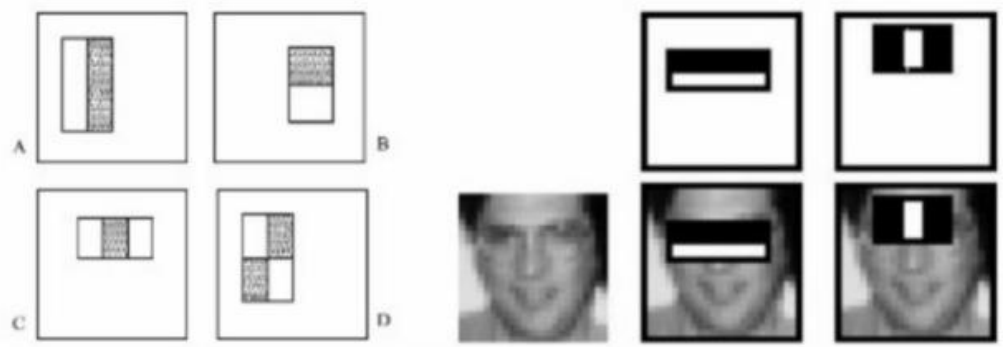

얼굴 인식 (openCV)

- **Cascade 방식**
  - 사람 얼굴 고유의 특징을 database화하여 이미지에서 추출하는 방법 사용
  - 연산이 복잡한 강 분류기를 모든 영역에 적용시키는 것은 비효율적
    - Object는 입력 영상의 일부분일 뿐 모든 부분에 퍼져 있지 않다는 가정
    - 예, 단체 사진에서 사람의 얼굴이 사진에서 차지하는 비율은 극히 일부분
  - 전체 특징을 여러 분류기 단계로 그룹화, 단계별로 하나씩 적용
    - 처음 몇 단계에는 매우 적은 수의 특징을 포함
    - 해당 단계에서 실패하면 나머지 특징에 대한 검출은 포기하고 바로 다음 창으로 이동
    - 통과하면 기능의 두 번째 단계를 적용하고 해당 특징들을 검출

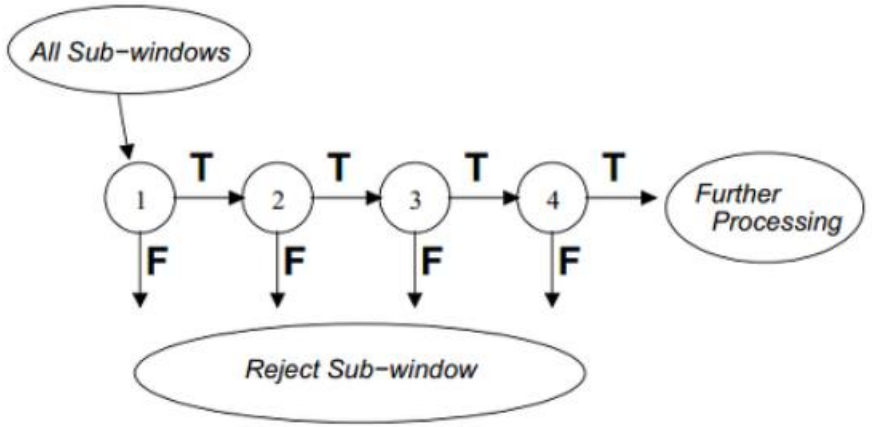

얼굴 인식 (openCV)

- Haar-like 특징 학습을 이용한 얼굴 인식
  - 단점
    - 영상의 밝기 값을 이용하기 때문에 조명,대조비에 많이 영향
    - sample의 양이나 질에 따라 성능에 크게 영향

실습

- OpenCV 예제 실습
  - <실습:gg-45-opencv_digit>
  - 손글씨 숫자 인식
    - 8x8 픽셀 숫자 이미지를 데이터로 SVM 분류기 학습하고 학습한 파라미터를 피클 형식 파일로 저장
    - 임의의 손글씨 숫자 이미지에 대해 인식 결과 확인
  - <실습:gg-46-object_detect>
  - 윤곽선 검출
    - 윤곽선 추출을 위해 그레이로 스케일링한 후 블러링을 통해 노이즈 제거
    - 이진화 수행

텍스트 분석

텍스트 분석의 개요

- 텍스트 분석의 목적
  - 텍스트의 의미를 알아내는 것
    - 글의 목적
    - 글쓴이의 성향(찬성/반대)
    - 기분(기쁨/슬픔/우울함 등)
    - 제품 피드백 등
- 텍스트 자체는 대표적인 비정형 데이터
- 의미를 추출하려면 비정형 데이터에서 정형화된 정보를 먼저 얻어야 함
- 텍스트 구문을 분석하여 의미를 파악하고 이것을 정량적으로 측정함

텍스트 분석

- SNS(트위터, 블로그, 페이스 북 등) 글을 분석
  - 소비자들의 반응, 감성, 트렌드를 파악
  - 개인별 마케팅, 상품 피드백을 분석하는데 사용
- 이메일, 웹사이트 댓글, 신문기사, 콜센터 상담기록, 도서 등을 분석
  - 글의 주요 내용을 파악
  - 문서의 특징을 추출
  - 유사한 글이나 저자를 찾는 작업 등을 수행
- 참고문헌이나 본문 인용의 관계를 통해서 문서간의 연계성, 전문가들의 인적 네트워크 등을 파악하는데도 사용
- 인공지능 스피커, 챗봇 등에서도 기본적으로 텍스트 분석이 필요

텍스트 분석 응용

- 챗봇 (Chatbot)
  - 사람과 대화하듯이 음성, 키보드 입력으로 대화를 나누는 인공지능 서비스
  - 챗봇의 유형
    - 미리 답을 준비하여 관련 질문이 나오면 해당 답을 하는 간단한 방식 (저수준)
    - 신경망을 사용하여 최적의 답을 찾아주는 방식 (고수준)

- QA 시스템
  - 질문을 하면 검색을 통해 적절한 답을 찾아주는(대답) 서비스
    - 대한민국의 수도는?
    - 오늘 날씨는?

- 자연어 처리
  - 언어 모델을 사용
    - 가장 자연스러운 다음 문장을 완성
    - 문장을 번역
    - 문서 요약, 주제 분석, 감성 분석 등을 수행

텍스트 표현 방법

- 사람이 단어나 문장의 의미를 인식하듯이 컴퓨터가 단어 자체 의미를 직접 파악할 수는 없다

- 텍스트 데이터 처리
  - 대표적인 비정형 데이터
  - 먼저 비정형 데이터인 글자로부터 정형화된 데이터인 수치 데이터로 변환

- 토큰화(tokenize) : 텍스트 분석의 첫 단계
  - 컴퓨터가 다루는 텍스트의 단위 : 토큰
    - 단어 (word) or 글자(character)
  - 주어진 텍스트를 토큰으로 나누는 작업

코퍼스 (말 뭉치)

- 말뭉치(corpus)
  - 데이터 분석에 주어진 전체 문서 집합
- 문서(document)
  - 코퍼스 내의 한 단위의 텍스트
  - 예) 하나의 블로그는 문서이고, 분석할 대상 블로그가 1천개이면 이 1천개 블로그 집합이 말뭉치
- 파싱(parsing)
  - 코퍼스에서 의미 있는 단어를 추출하는 작업

토큰화

- 토큰화 단위 (크게 3가지)
  - 단어(word)
    - 사람이 말을 이해할 때, 단어 단위로 인식하기 때문에 많은 연구에서 선호
  - 글자(character)
  - n-gram
- 단어 단위로 정보를 표현하는 과정에서 많은 정보를 잃게 된다
  - “정말”, “정말로”, “정말은” 등 단어
    - 같은 단어로 취급, 아니면 각각 다른 단어로 처리할지에 따라 분석 결과 달라짐
    - 같은 단어로 취급하기 위해 단어를 어근(stem)으로 변환하면 어미 변화를 무시하거나 조사를 무시하게 되어 텍스트에 들어 있던 정보를 잃게 된다
- 일반적으로 단어의 종류는 보통 10만 단어 이상 (언어마다 상이)
  - 신조어, 특수한 단어 포함하면 수십만개로 확대

토큰화

- 글자 단위로 토큰화를 하면 어근으로 변환할 때 정보를 잃는 문제를 피할 수 있다.
  - “정”, “말 “, “로”, “은 “ 등
- 음절 단위 토큰의 수
  - 영어
    - 음절단위의 토큰의 수가 매우 적다 : 알파벳이 26글자
  - 한글
    - 음절의 수가 수천 가지 이상

토큰화 – n-gram

- n-gram
  - n개의 연속된 단어를 하나로 취급하는 방법

- 예를 들어 “러시아 월드컵” 이라는 표현을 “러시아” 와 “월드컵” 두 개의 독립된 단어로만 취급하지 않고 두 단어로 구성된 하나의 토큰으로 취급
  - n=2 경우, bi-gram
  - 단어의 수가 매우 크게 증가
    - 실제로는 빈도 수가 최소한 몇 개 이상인 것만 다룬다

토큰화 – n-gram (예)

텍스트: “어제 러시아에 갔다가 러시아 월드컵을 관람했다”

단어토큰: { “어제”, “러시아”, “갔다”, “러시아”, “월드컵”, “관람” }

2-gram 토큰: { “어제 러시아”, “러시아 갔다”, “갔다 러시아”, “러시아 월드컵”, “월드컵 관람” }

토큰화

- n-gram을 허용하면 토큰화 대상의 수가 매우 크게 증가
  - 이론적으로는 10만개의 단어를 두 개 붙여서 나올 수 있는 경우의 수는 10만의 자승이 된다.
- 실제로는 빈도수가 최소한 몇 개 이상인 것만을 다룬다.
- 토큰화한 결과를 수치로 만드는 방법
  - 원핫(one-hot) 인코딩
  - BOW(단어모음)
  - 단어벡터(Word Vector) 방법

원 핫 (One-hot) 인코딩

- **원 핫 인코딩**
  - **토큰**에 고유 번호를 배정
  - 모든 고유번호 위치의 한 컬럼만 1, 나머지 컬럼은 0인 **벡터**로 표시

텍스트: "어제 러시아에 갔다가 러시아 월드컵을 관람했다"

토큰 사전: { "어제" :0, "러시아" :1, "갔다" :2, "월드컵" :3, "관람" :4}

원핫 인코딩:

어제 = [1, 0, 0, 0, 0]
러시아 = [0, 1, 0, 0, 0]
갔다 = [0, 0, 1, 0, 0]
월드컵 = [0, 0, 0, 1, 0]
관람 = [0, 0, 0, 0, 1]

BOW (Bag of Word, 단어 모음)

- 원핫 인코딩 방식으로 단어(토큰)을 표현하면
  - 단어의 수가 적을 때에는 문제가 안되지만
  - 단어가 모두 10만개이면
    - 모든 단어가 항목이 10만개인 (0과 1로 구성된) 벡터로 표시
  - 주어진 텍스트가 20개의 단어로 구성되어 있다면
    - 20 x 100,000개 크기의 벡터가 필요
- 텍스트 분석은 "문장" 을 단위로 하는 경우가 많다
- 단어 모음(BOW) 방식 : 한 문장을 하나의 벡터로 만드는 방법
  - 한 문장을 단어 사전 크기의 벡터로 표현하고 그 문장에 들어 있는 단어의 컬럼만 1로, 단어가 없는 컬럼은 모두 0으로 표현
- 먼저 단어 사전을 만들고 각 문장에 어떤 단어가 들어 있는지 조사하여 해당 컬럼만 1로, 나머지는 0으로 코딩

BOW

- 단어 사전: { “어제” :0, “오늘” :1, “미국” :2, “러시아” :3,
  “갔다” :4, “축구” :5, “월드컵” :6, “올림픽” :7,
  “관람” :8, “나는” :9, …, “중국” :4999 }
- Text_1: “어제 러시아에 갔다가 러시아 월드컵을 관람했다” 를 BOW로 표현하면

문장번호	0	1	2	3	4	5	6	7	8	9	10	…	4998	4999
Text_1	1	0	0	1	1	0	1	0	1	0	0	0	0	0
Text_2	0	0	0	0	0	0	0	0	0	0	0	0	0	0
Text_3	0	0	0	1	0	0	0	0	0	0	0	0	0	0
Text_4	0	0	0	0	0	0	0	1	0	0	0	0	1	0
…														
Text_50	0	0	0	0	0	0	1	0	0	0	0	0	0	0

BOW

- **문서-단어(document-term) 행렬**
  - 문장 단위로 어떤 단어들이 있는지를 나타내는 BOW의 확장
  - 문서(document) 단위로 어떤 단어들이 있는지를 표현
  - 같은 단어가 여러번 등장하면 1 이상의 값을 갖는다

문서번호	0	1	2	3	4	5	6	7	8	9	10	...	4998	4999
Doc_1	1	2	3	1	4	0	2	0	1	3	0	0	0	0
Doc_2	0	0	0	0	2	0	0	0	0	0	0	0	2	0
Doc_3	0	0	0	1	0	0	0	0	3	0	0	0	0	1
Doc_4	4	0	0	0	0	0	0	1	0	0	4	0	1	0
...														
Doc_100	0	2	0	0	0	0	1	4	0	1	0	0	0	0

BOW (Bag of Word, 단어 모음)

- **BOW(Bag of Words)**
  - 머신러닝에서 텍스트 데이터를 표현하는 방법으로 널리 쓰임
  - 전체 말뭉치(corpus)에 대한 BOW 표현 계산
    - 토큰화 – 각 문서를 문서에 포함된 단어(토큰)로 나눔
    - 어휘 사전 구축 – 모든 문서에 나타난 모든 단어 목록(알파벳순)
    - 인코딩 – 어휘 사전의 단어가 문서마다 몇 번 나타나는지 셈

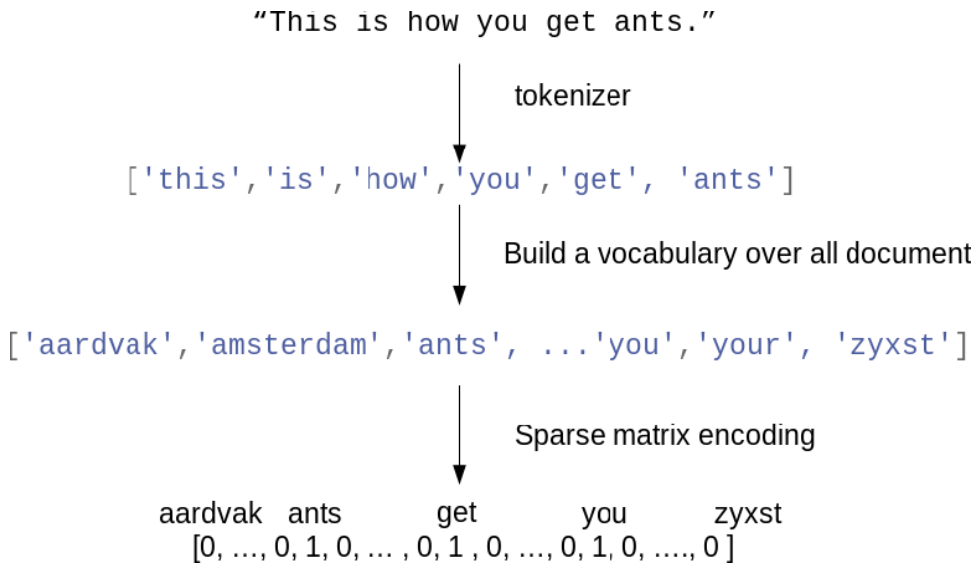

tf-idf

- term frequency-inverse document frequency
  - tf : 단어가 각 문서에서 발생한 빈도
  - df(document frequency) : 그 단어가 등장한 '문서' 의 빈도
- 적은 문서에서 발견될수록 가치 있는 정보
- 많은 문서에 등장하는 단어일수록 일반적인 단어
  - 이러한 공통적인 단어는 tf가 크다고 하여도 비중을 낮추어야 분석이 제대로 이루어질 수 있다.
- 따라서 단어가 특정 문서에만 나타나는 희소성을 반영하기 위해서 idf(df의 역수)를 tf에 곱한 값을 tf 대신 사용
  - $tfidf(w,d) = tf\left(log\left(\frac{N+1}{N_w+1}\right)+1\right)$
  - Tf: 단어 w가 대상 문서 d에 나타난 횟수
  - N: 훈련 세트에 있는 문서 수, N_w: 단어 w가 포함된 훈련세트 문서 수
- Sklearn에서는 Tfidf 변환을 위한 2개의 클래스 제공
  - TfidfTransformer – countvectorizer가 만든 희소행렬을 변환
  - TfidfVectorizer – 텍스트 데이터를 입력받아 BOW 특성 추출 및 tfidf 변환 수행
  - 둘 다 적용 후 L2 정규화를 적용하므로 데이터 크기에 상관없음

실습

- BOW 예제 실습
  - <실습:gg-51-뉴스기사>
  - 뉴스기사를 활용하여 문서단어행렬 제작
    - 국내언론사들의 뉴스기사 데이터를 읽고 CountVectorizer를 이용하여 문서-단어 행렬을 저장하고 빈도 수 확인
    - TfIdfVectorizer 로 문서-단어 행렬 저장
  - <실습:gg-52-스팸분류>
  - 영어 문자메시지 중에서 스팸 및 정상 메시지 구분
    - 영어 문자 데이터를 읽고 tfidf를 구하고 다양한 머신러닝 알고리즘을 통해 스팸메일 분류 및 비교분석
  - <실습:gg-53-네이버영화평점>
  - 네이버 영화 평점 데이터를 이용한 감성 분석
    - 네이버 영화 평점 데이터를 읽고 konlpy 패키지를 이용하여 한글 형태소 분석 후 로지스틱 회귀를 통해 분류

단어 임베딩

단어 임베딩의 정의

- 앞에서 소개한 세 가지 텍스트 코딩 방식인 원핫 인코딩, BOW(단어모음), 문서-단어 행렬방식은 단어마다 고유번호를 배정하여 사용
- 그러나 이 고유 번호 숫자에는 아무런 의미가 들어 있지 못하며 단지 인덱스의 성격만 갖는다.
- 단어를 인덱싱이 아니라, 의미 있는 숫자 들의 집합, 즉, 벡터로 표현하는 방법이 단어 임베딩 (Word Embeding)이다.

단어 벡터

- 단어 벡터
  - 각 단어를 50~300개 정도의 차원으로 구성된 벡터로 표현

    학교 = [0.23, 0.58, 0.97, … , 0.87, 0.95]

    바다 = [0.45, 0.37, 0.81, … , 0.22, 0.64]

- 단어 벡터를 사용하면
  - 각 단어들 사이의 "거리" 를 계산이 가능
  - 거리를 기반으로 유의어/반대어 등을 찾아낼 수 있다
  - 동물의 성별, 단수/복수, 동사/명사를 구분할 수도 있다
  - 그러나 각 벡터 값의 의미는 알 수 없다

단어 벡터

- 단어 벡터는 대형 말뭉치로부터 학습
  - 말뭉치의 문장들을 계속 입력하여 학습을 시키면 단어 벡터를 얻을 수 있다
  - 예를 들어 음식과 관련된 다음과 같은 문장들로 학습을 시키면 다음과 같은 단어 벡터를 얻을 수 있을 것이다.
  - 학습에 사용된 문장 예:

"나는 어제 바나나를 맛있게 먹었다"
"이 망고는 먹기가 힘들다"
"이 사과는 씹는 맛이 아주 좋다"
"바나나가 사과보다 맛있다"
"잘 씹어야 맛있게 먹을 수 있다"
…

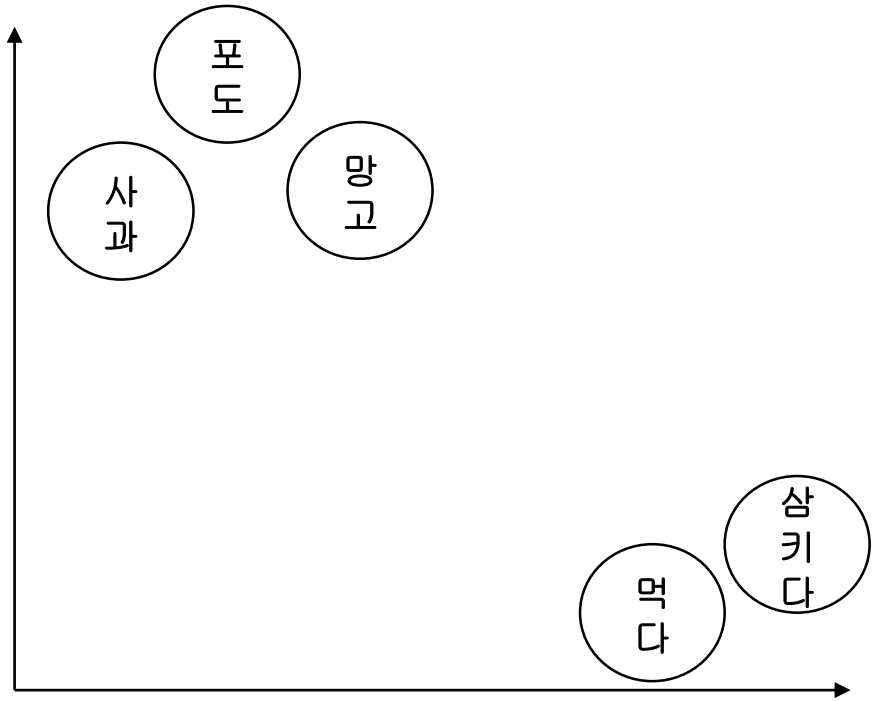

단어 벡터

- **이미 만들어져 있는 단어 벡터를 가져다 사용할 수도 있다.**
- **glove**
  - **2014년 스탠포드에서 만든** Global Vectors for Word Representations
  - **위키피디아 데이터로부터 학습**
  - **40만개 단어를 100차원으로 임베딩**
  - npl.stanford.edu/projects/glove **에서 다운로드**

단어 벡터

- 단어 벡터를 사용한 A:B = C: ?의 관계를 만족하는 ?를 찾을 수 있다.
  - 왕 : 여왕 = 아들 : ? → ? 부분 : 딸
  - 이러한 연산은 (B-A) 벡터, 즉 (왕 – 여왕) 성분을 구한 후 이를 벡터 C(아들)에 더하면 딸을 구할 수 있다.
  - 이들의 관계는 아래와 같다.

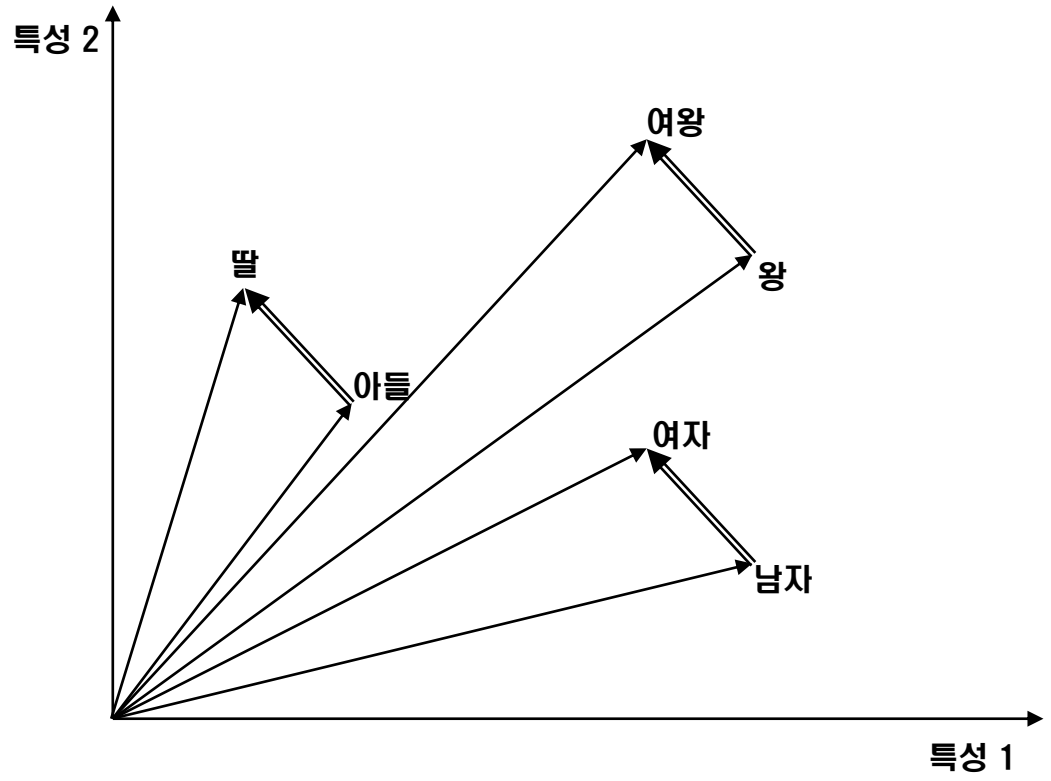

단어 벡터

- 학습 방법
  - 한 단어 w 가 주어졌을 때 그 주변 단어가 존재하면 0, 그렇지 않으면 1인 원-핫 인코딩을 생성하여 학습
- 구현 방법
  - 스킵-그램(skip-gram)
    - 단어(xi)에 대해 주변에 나타날 확률이 높은 단어들(context)을 구함, 즉 p(context|xi) 를 구함

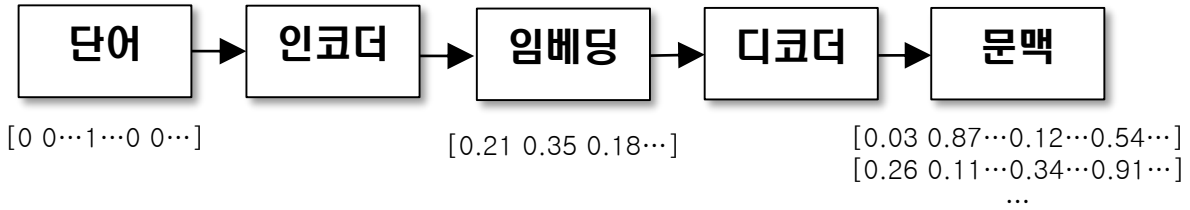

  - CBOW(Continuous bag-of-words)
    - 주변 단어(context)를 받아 그 단어들과 같이 나타날 확률이 높은 단어(xi)을 구함, 즉 p(xi |context)

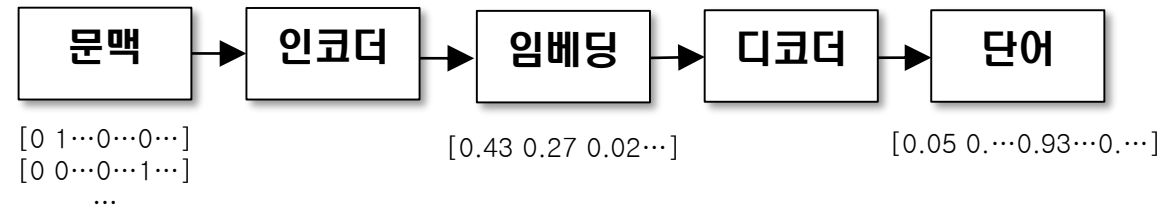

단어 벡터

- 구조
  - 신경망으로 분산표현을 학습하여 모델 구현

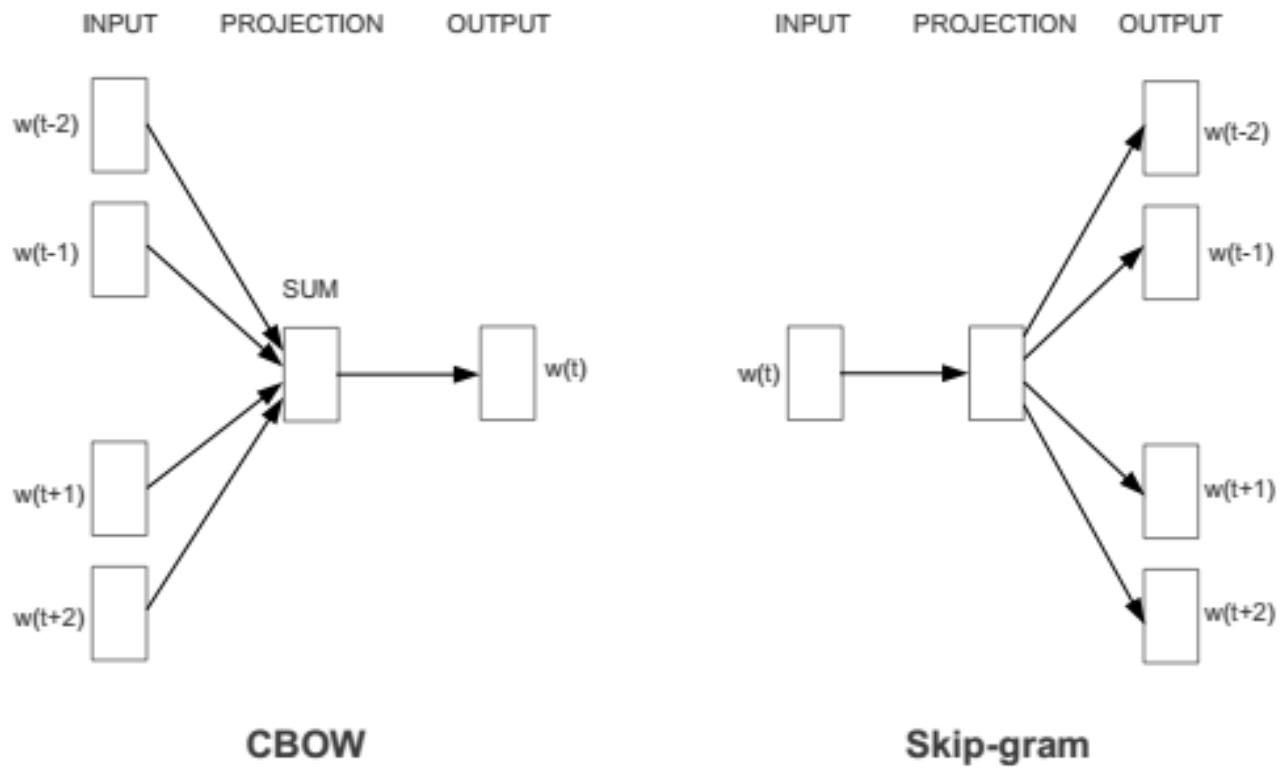

네이버 영화 평점 분석

- **네이버 영화 평점 데이터를 이용한 감성분석 방법을 소개**
  - **문서-단어 행렬을 이용**
  - **데이터**
    - Naver sentiment movie corpus v1.0 (github.com/e9t/nsmc/) **사용**
    - **영화 리뷰 20만 건이 저장**
    - **각 평가 데이터는 0과 1로 레이블링 (0 : 부정, 1 : 긍정 리뷰)**
  - **한글 자연처 처리**
    - konlpy **패키지에서 제공하는** Twitter **문서 분석 라이브러리를 사용**

단어 벡터 생성

- **단어 벡터 만드는 과정을 소개**
  - **가장 널리 사용되는 라이브러리 : Gensim**
    - pip install gensim

```
from gensim.models.word2vec import Word2Vec
model = Word2Vec(sentense_list, min_count=1)
model.most_similar(positive="조선")

##
[('일본', 0.9953970909118652),
 ('관련', 0.9941188097000122),
 ('인물', 0.9938454031944275),
 ('러시아', 0.9931197166442871),
 ('주요', 0.9918481111526489),
 ('대원군', 0.9915156960487366),
...
```

문장 유사도 측정

- 단어의 유사도
  - 두 개의 문자열이 얼마나 다른지를 나타내는 편집 거리를 이용
- 편집 거리
  - 한 단어에서 다른 단어로 바꿀 때 필요한 최소한의 편집 행동의 횟수
  - 편집 행동
    - 글자를 추가, 제거, 변경
- 두 문장의 편집 거리 계산
  - NLTK 라이브러리를 활용

실습

- 단어 벡터 예제 실습
  - <실습:gg-54-단어벡터>
  - 뉴스기사를 활용하여 단어벡터 제작
    - 국내언론사들의 뉴스기사 데이터를 읽고 단어벡터를 제작하고 단어의 유사도 확인
  - 문장유사도 분석
    - Nltk 라이브러리를 활용하여 문장 간 편집거리 계산 및 ngrams 분석

형태소 분석

- 단어 구분
  - 영어
    - 단어들이 대부분 스페이스로 구분, 단어 구분이 어렵지 않다
    - 예) I am a boy
  - 한글
    - 스페이스로 나눠진 단어가 조사를 포함하거나 복합명사인 경우 등이 있어 품사를 구분하는 작업이 영어처럼 간단하지 않다
    - 예) 나는 소년이다
      - 단어 구분 : '나는', '소년이다'
      - 추가적인 형태소 분석 : '나 ', '는', '소년 ', '이다 '
- 형태소 분석(morphological analysis)
  - 한글 문장을 처리하려면 단어를 다시 더 작은 단위인 형태소로 나누는 절차가 필요

KoNLPy 형태소 분석기

- KoNLPy 형태소 분석기
  - 한국어 자연어 처리를 위한 파이썬 모듈
  - http://konlpy.org
- 구성
  - Tag 서브패키지 – 형태소 분석기 엔진
    - Hannanum (한나눔) : KAIST
    - Kkma (꼬꼬마) : 서울대
    - Komoran (코모란) : Shineware
    - Mecab (메카브) - 일본어용 형태소 분석기를 한국어 사용할 수 있도록 수정
    - Twitter (Okt, Open-korean-text) : twitter 개발
    - analyze(형태소 후보, Hannanum), morphs(형태소 파싱), nouns(명사 추출), pos(POS 태거) 메소드 포함
  - Corpus 서브패키지 – 다양한 말뭉치 포함
    - Kolaw(대한민국헌법), kobill(법률)
  - 기타 모듈
    - data(패키지경로), downloader(konlpy서버데이터접근), jvm(JVM초기화), utils(코드변환,csv파일처리,텍스트출력 등)

실습

- 형태소 분석 예제 실습
  - <실습:gg-55-형태소_분석>
  - 한글 형태소 분석기인 konlpy 실습
    - Konlpy 라이브러리를 활용하여 한글 형태소 분석

토픽 모델링

- 토픽 모델링
  - 문서의 주제(카테고리)를 구분하는 것
  - 미리 카테고리가 정해져 있지 않으므로 비지도 학습에 해당
- 관련된 단어나 문서의 집합을 찾는 방법이 필요
  - 잠재 디리클레 할당, LDA(Latent Dirichlet Allocation) 방법을 주로 사용
  - 관련성이 높은 단어들이 발생 → 같은 토픽으로 분류
- 한 문서에는 여러 토픽이 복합적으로 존재할 수 있다
  - 각 토픽의 비중은 다를 수 있다

LDA (Latent Dirichlet Allocation)

- LDA
  - 문서의 각 토픽들이 디리클레 분포를 따른다고 가정
  - 각 문서를 각 토픽에 “할당” 하는 방식으로 동작
    - 문서마다 토픽이 어떻게 분포되어 있는지, 그리고 토픽마다 단어의 분포가 어떤지 파악
    - 토픽에 따라 단어의 분포를 결정하고 그중 가장 높은 확률의 단어를 선택

LDA

- **LDA**
  - **말뭉치로부터 대표적인 토픽을 먼저 선정**
  - **해당 토픽으로부터 단어들을 뽑아서 문서를 생성**

- LDA**의 학습 과정**
  - **주어진 문서에 등장한 단어들이 어떤 토픽에서 뽑혔고**
  - **그 토픽의 확률이 어떻게 분포하였는지를 추론해 내는 것**

- **말뭉치의 단어가 어떤 토픽에 해당하는지 명시적으로 표시되어 있지 않기 때문에 학습을 통해 '잠재적' 인 정보를 추출해야한다**

뉴스 분석 실습

- 토픽 모델링 예제 실습
  - <실습:gg-56-토픽모델링>
- 뉴스기사를 사용하여 토픽 모델링을 수행하는 예
  - 먼저 여러 문서에서 자주 나타나는 공통 단어를 제거
  - 상위 10,000개의 단어를 선택하여 BOW 모델을 생성
- LDA 분석으로 얻은 결과는 주제를 구별하는데 도움을 주지만 비지도 학습이기 때문에 완벽한 정답은 아니다
  - 주제에 할당된 문서를 확인하여 평가, 검증하는 과정은 사람이 해주어야 한다

수고하셨습니다.

Q & A